

Generative Semi-Supervised & Active Learning για Δίκαιη Προβλεπτική Ανάλυση στην Εγκατάλειψη Φοιτητών

Μια ολοκληρωμένη (end-to-end) μελέτη generative oversampling, active learning οδηγούμενου από reinforcement learning, in-processing μετριάσμού της μεροληψίας (fairness), και multimodal σύντηξης κειμένου, πάνω στο dataset UCI *Predict Students' Dropout and Academic Success*.

Μια αυτοτελής εμπειρική διερεύνηση, χτισμένη πάνω στην πρόταση του project, στο στρατηγικό roadmap των αναβαθμίσεων, και σε τέσσερις σύγχρονες αναφορές MDPI.

Σύνολο δεδομένων:	UCI <i>Predict Students' Dropout and Academic Success</i> (4 424 γραμμές, 37 στήλες)
Πρόβλημα:	Διαδική ταξινόμηση — Dropout (θετική κλάση) vs. Graduate/Enrolled
Προστατευόμενο χαρακτηριστικό:	Gender (δυναμικό)
Pipeline:	10 φάσεις — Preprocessing → Baselines → VAE → TabDDPM → Uncertainty AL → RL AL → Post-hoc fairness → In-processing fairness → DistilBERT multimodal → Aggregation
Βέλτιστη διαμόρφωση:	Multimodal (tabular + DistilBERT) — $F1 \approx 0.85$, $AUC \approx 0.96$ (μέσος όρος σε 10 seeds)

Περίληψη

Η παρούσα αναφορά τεκμηριώνει μια ολοκληρωμένη (end-to-end) μεθοδολογική μελέτη τεχνικών generative, semi-supervised, active, fair και multimodal μάθησης, εφαρμοσμένων στην πρόβλεψη εγκατάλειψης φοιτητών (student dropout) πάνω στο dataset UCI *Predict Students' Dropout and Academic Success* [Realinho et al. \(2022\)](#). Ξεκινά με από τρία ισχυρά supervised baselines — Random Forest, XGBoost, και ένα PyTorch Multi-Layer Perceptron — και εισάγουμε σταδιακά τέσσερις αναβαθμίσεις πάνω σε μια πιστή επανυλοποίηση της αρχικής πρότασης του project. Η **Αναβάθμιση 1** αντικαθιστά έναν Variational Autoencoder oversampler [Kingma and Welling \(2014\)](#); [Kostopoulos et al. \(2025\)](#) με ένα εξατομικευμένο Tabular Denoising Diffusion Probabilistic Model [Ho et al. \(2020\)](#); [Kotelnikov et al. \(2023\)](#), ταιριάζοντας καλύτερα την πραγματική διασπορά των synthetic numerical χαρακτηριστικών (υποδιπλασιάζοντας την ασυμφωνία τυπικής απόκλισης, αν και με αντίστοιχο κόστος στο σφάλμα μέσου), ενώ αποκάλυπτε και επιλύει μια παγίδα *categorical mode-collapse* μέσω per-block categorical likelihoods που υλοποιούνται ως hard one-hot δείγματα [Jang et al. \(2017\)](#); [Maddison et al. \(2017\)](#). Η **Αναβάθμιση 2** αντικαθιστά το στατικό entropy-based uncertainty sampling [Lewis and Gale \(1994\)](#); [Settles \(2009\)](#) με έναν DQN-style reinforcement-learning agent [Mnih et al. \(2015\)](#); [Fang et al. \(2017\)](#), του οποίου το state είναι μια 20-διάστατη σύνοψη του pool και του οποίου το reward shaping χρησιμοποιεί το κέρδος σε F1 αντί για κέρδος σε accuracy, προλαμβάνοντας και αποφεύγοντας τον τρόπο αποτυχίας *reward-hacking* που καταγράφεται στην ανασκόπηση human-in-the-loop των [Lazaros et al. \(2026\)](#). Η **Αναβάθμιση 3** αντικαθιστά έναν post-hoc έλεγχο fairness με μια in-processing ποινή demographic-parity [Zafar et al. \(2017\)](#); [Agarwal et al. \(2018\)](#); [Raftopoulos et al. \(2025a\)](#) και σαρώνει την ισχύ regularisation λ ώστε να ιχνηλατήσει ένα εμπειρικό Pareto frontier accuracy-fairness: στα δέκα seeds, το $\lambda = 1$ μειώνει το demographic-parity χάσμα από 0.211 σε 0.083 ($\sim 60\%$, $p = 0.002$) με κόστος ~ 1.6 μονάδων accuracy. Η **Αναβάθμιση 4** συντήκει μια frozen DistilBERT [Sanh et al. \(2019\)](#) κωδικοποίηση προσομοιωμένου (simulated) feedback φοιτητών με τα tabular χαρακτηριστικά, παράγοντας την ισχυρότερη διαμόρφωση της μελέτης ($F1 \approx 0.85$, $AUC \approx 0.96$, μέσος όρος σε δέκα seeds, στατιστικά σημαντική σε κάθε seed) — αν και, επειδή το κείμενο είναι simulated και εξ ορισμού συσχετισμένο με την ετικέτα, το αναφέρουμε ως *οροφή* (άνω φράγμα) και όχι ως αναπτύξιμο αποτέλεσμα, σε συμφωνία με τη βιβλιογραφία multimodal sentiment για την εγκατάλειψη [Zerkouk et al. \(2025\)](#). Κάθε αναβάθμιση παρουσιάζεται ως αφήγηση *πρόβλημα που εντοπίστηκε* $\rightarrow$ *μετριασμός που σχεδιάστηκε* $\rightarrow$ *εμπειρική τεκμηρίωση*, και κάθε συγκριτικός ισχυρισμός επικυρώνεται σε δέκα τυχαία seeds με paired test στατιστικής σημαντικότητας και bootstrap διαστήματα εμπιστοσύνης στις κύριες μετρικές. Διερευνούμε περαιτέρω την εξωτερική εγκυρότητα αναπαράγοντας ολόκληρη τη μελέτη σε ένα δεύτερο cohort (το Open University Learning Analytics Dataset) και επικυρώνοντας το protocol σύντηξης κειμένου σε ένα πραγματικό σώμα εκπαιδευτικού κειμένου: τα model-agnostic ευρήματα (το oversampling δεν βοηθά, το diffusion ταιριάζει καλύτερα τη synthetic διασπορά) αναπαράγονται, ενώ τα φαινόμενα active-learning και fairness αποδεικνύονται εξαρτώμενα από το dataset. Το πλήρες pipeline είναι αναπαραγωγίσιμο από το raw CSV έως την τελική συγκεντρωτική σύγκριση μέσω δέκα σύντομων Python scripts. Όλος ο κώδικας, τα δεδομένα, οι JSON μετρικές, και ένα πλήρες σύνολο figures διατίθενται μαζί με τον πηγαίο κώδικα του παρόντος εγγράφου.

Λέξεις-κλειδιά: educational data mining, student-dropout prediction, tabular variational autoencoder, diffusion model, active learning, deep Q-network, in-processing fairness, demographic parity, Pareto frontier, multimodal learning, DistilBERT, Gumbel-Softmax.

Περιεχόμενα

1	Εισαγωγή	1
1.1	Διατύπωση του προβλήματος και κίνητρο	1
1.2	Σκοπός και συνεισφορές	1
1.3	Οργάνωση του εγγράφου	3
2	Ανασκόπηση Βιβλιογραφίας	3
2.1	Συνθετικά δεδομένα για semi-supervised EDM (Kostopoulos et al., 2025)	3
2.2	Self-labelled SSL για πρόβλεψη εγκατάλειψης σε MOOC (Raftopoulos et al., 2025b)	4
2.3	Human-in-the-loop AI: ένα ενοποιημένο πλαίσιο σχεδίασης (Lazaros et al., 2026)	4
2.4	Fairness-aware ML: ένα ολοκληρωμένο benchmark (Raftopoulos et al., 2025a)	5
2.5	Ευρύτερο τοπίο	5
3	Περιγραφή Συνόλου Δεδομένων & Διερευνητική Ανάλυση	6
3.1	Επισκόπηση του dataset	6
3.2	Train / test split και one-hot επέκταση	6
4	Μεθοδολογία	8
4.1	Baseline supervised learning (Φάση 2)	8
4.2	Generative data augmentation	8
4.2.1	Tabular Variational Autoencoder (Φάση 3)	9
4.2.2	Tabular Denoising Diffusion (Φάση 4, Αναβάθμιση 1)	10
4.2.3	Γιατί έχει σημασία η αναβάθμιση: κατανομική πιστότητα	10
4.2.4	Κλασικό baseline: SMOTE oversampling (Φάση 3b)	11
4.3	Active learning	11
4.3.1	Uncertainty sampling (Φάση 5)	11
4.3.2	Reinforcement-learning acquisition (Φάση 6, Αναβάθμιση 2)	11
4.4	Fairness-aware μάθηση	12
4.4.1	Fairness metrics	12
4.4.2	In-processing demographic-parity penalty (Φάση 8, Αναβάθμιση 3)	12
4.5	Multimodal επέκταση (Φάση 9, Αναβάθμιση 4)	13
5	Πειραματική Διάταξη	13
5.1	Υλικό και λογισμικό	13
5.2	Αναπαραγωγίμο pipeline	13
5.3	Πρωτόκολλο αξιολόγησης	14
5.4	Πρωτόκολλο αξιοπιστίας multi-seed	14
5.5	Bootstrap διαστήματα εμπιστοσύνης	15
6	Αποτελέσματα & Συζήτηση	15
6.1	Φάση 2 — Baseline supervised επίδοση	15
6.2	Φάση 3 — VAE oversampling	16
6.3	Φάση 4 (Αναβάθμιση 1) — Diffusion vs. VAE	17
6.4	Φάση 3b — SMOTE: το κλασικό oversampling baseline	18
6.5	Φάση 5 — Uncertainty sampling vs. random	19
6.6	Φάση 6 (Αναβάθμιση 2) — RL-based active learning	19
6.7	Self-labelled SSL baseline: Co-Forest και Self-Training	20
6.8	Φάση 7 — Post-hoc έλεγχος fairness	22
6.9	Φάση 8 (Αναβάθμιση 3) — In-processing fairness penalty	23
6.10	Φάση 9 (Αναβάθμιση 4) — Multimodal DistilBERT επέκταση	25
6.11	Φάση 9b — επικύρωση του fusion protocol σε πραγματικό κείμενο	26

6.12	Επανεκτίμηση σύγχρονων ισχυρισμών “multimodal-dropout”	28
6.13	Cross-phase σύνθεση	29
6.14	Αξιοπιστία μεταξύ seeds	29
6.15	Γενίκευση σε ένα δεύτερο dataset (OULAD)	31
7	Εντοπισμένες Προκλήσεις και οι Μετριάσμοί τους	32
7.1	Αναβάθμιση 1: Από VAE σε TabDDPM diffusion	32
7.2	Αναβάθμιση 2: Από uncertainty sampling σε έναν Reinforcement-Learning DQN	33
7.3	Αναβάθμιση 3: Από post-hoc fairness σε in-processing fairness	34
7.4	Αναβάθμιση 4: Από tabular-only σε multimodal DistilBERT χαρακτηριστικά	35
7.5	Άλλες παρατηρήσεις και συγκρίσεις εκτός εμβέλειας	36
8	Συμπεράσματα και Μελλοντική Εργασία	37
A'	Αποσπάσματα Κώδικα Υλοποίησης	42
1.1	Κοινό module προεπεξεργασίας (common.py)	42
1.2	Tabular VAE (phase3_vae.py)	43
1.3	Πυρήνας TabDDPM (phase4_diffusion.py)	43
1.4	DQN-based active learner (phase6_rl_AL.py)	44
1.5	In-processing fairness MLP (phase8_fairness_inprocess.py)	45
1.6	Multimodal DistilBERT encoder (phase9_multimodal_bert.py)	45
1.7	Σενάριο εκτέλεσης (driver)	46

1 Εισαγωγή

1.1 Διατύπωση του προβλήματος και κίνητρο

Η εγκατάλειψη φοιτητών (student dropout) είναι ένα από τα πιο καθοριστικά αρνητικά αποτελέσματα στην τριτοβάθμια εκπαίδευση. Τα πανεπιστήμια χάνουν έσοδα από δίδακτρα και ρυθμό αποφοίτησης· οι φοιτητές που εγκαταλείπουν χάνουν συσσωρευμένο χρόνο, συσσωρευμένο χρέος, και το πτυχίο για το οποίο ήρθαν· και ολόκληροι πληθυσμοί χάνουν την ανύψωση κοινωνικής κινητικότητας που τυπικά προσφέρει ένα ολοκληρωμένο πτυχίο. Η συνύπαρξη αυτών των κοστών έχει καταστήσει τα συστήματα έγκαιρης προειδοποίησης (early-warning) για την εγκατάλειψη μία από τις πιο ευρέως μελετημένες εφαρμογές του *Educational Data Mining* (EDM) [Romero and Ventura \(2020\)](#); [Aljohani et al. \(2019\)](#).

Τα σύγχρονα συστήματα έγκαιρης προειδοποίησης στο EDM δεν είναι, ωστόσο, καθαρά ζήτημα προβλεπτικής επίδοσης. Τέσσερις *ταυτόχρονοι* περιορισμοί πρέπει να τηρούνται όταν ένα τέτοιο σύστημα αναπτύσσεται:

1. **Ανισορροπία κλάσεων και καθεστώς μικρών δεδομένων.** Οι περιπτώσεις εγκατάλειψης είναι συνήθως μειοψηφική ομάδα σε κάθε μάθημα, και οι ετικέτες (*εγκατέλειψε τελικά ο φοιτητής;*) είναι ακριβές στην απόκτησή τους, καθώς υλοποιούνται μόνο στο τέλος του ακαδημαϊκού έτους, υπό την προϋπόθεση ότι υπάρχουν πλήρη δεδομένα εγγραφής. Ένα πρακτικό σύστημα πρέπει είτε να κάνει oversample τη μειοψηφική κλάση *generatively*, είτε να μαθαίνει αποδοτικά από ένα μικρό labelled pool.
2. **Αποδοτικότητα στην ανάθεση ετικετών (labelling efficiency).** Τα εκπαιδευτικά ιδρύματα δεν μπορούν να επισημάνουν εξαντλητικά όλες τις ιστορικές τους ομάδες, οι σύμβουλοι και οι γραμματείς είναι ακριβοί. Το active learning προσφέρει μια εναλλακτική, ευαίσθητη στον προυπολογισμό.
3. **Αλγοριθμική δικαιοσύνη (fairness).** Τα μοντέλα πρόβλεψης εγκατάλειψης τελικά χρησιμοποιούνται για *παρέμβαση* στους φοιτητές — επιπλέον καθοδήγηση, υποχρεωτικές ομάδες μελέτης, σημάνσεις επιτήρησης. Ένα μοντέλο του οποίου τα ποσοστά παρέμβασης διαφέρουν ανά φύλο, εθνότητα, ή κοινωνικοοικονομικό στρώμα θα αναπαράγει ή θα ενισχύσει μηχανιστικά τις ανισότητες που κωδικοποιούνται στα ιστορικά δεδομένα. Η δικαιοσύνη πρέπει να σχεδιάζεται εξ αρχής, όχι να μπαλώνεται εκ των υστέρων [Mehrabi et al. \(2021\)](#); [Raftopoulos et al. \(2025a\)](#).
4. **Ετερογενή και multimodal δεδομένα.** Τα πραγματικά αρχεία φοιτητών περιλαμβάνουν όχι μόνο tabular δημογραφικά και βαθμούς αλλά και αντικείμενα ελεύθερου κειμένου — forum posts, σημειώσεις καθοδήγησης, σχόλια αξιολόγησης μαθημάτων. Η αιχμή της τεχνολογίας έχει μετατοπιστεί από καθαρά tabular μοντέλα σε multimodal που συντήκουν κείμενο με τις δομημένες στήλες [Zerkouk et al. \(2025\)](#).

Η παρούσα εργασία αντιμετωπίζει και τους τέσσερις περιορισμούς σε ένα συνεκτικό πειραματικό pipeline πάνω στο dataset *UCI Predict Students' Dropout and Academic Success* [Realinho et al. \(2022\)](#).

1.2 Σκοπός και συνεισφορές

Το παρόν project ακολουθεί μια σκόπιμα στρωματοποιημένη δομή. Ξεκινάμε από την επίσημη πρόταση — τρία supervised baselines, ένα VAE για minority oversampling, active learning βασισμένο σε uncertainty, και έναν post-hoc έλεγχο fairness. Στη συνέχεια υλοποιούμε τέσσερις *στρατηγικές αναβαθμίσεις*, καθεμία υποκινούμενη από έναν συγκεκριμένο περιορισμό της πρότασης που αναδύεται κατά την εμπειρική εργασία. Συγκεκριμένα, οι συνεισφορές μας είναι:

- Ένα αναπαραγώγιμο, end-to-end pipeline (δέκα φάσεις συν ένα SMOTE baseline και μια ανάλυση bootstrap-CI) που αναγεννά κάθε μοντέλο, μετρική, figure, και πίνακα σύγκρισης από το raw CSV με μία μόνο εντολή.

- Ένα *auspicious* protocol αξιολόγησης, ακόμη σπάνιο σε αυτή τη βιβλιογραφία: κάθε κύρια σύγκριση επαναλαμβάνεται σε δέκα τυχαία seeds με paired Wilcoxon test σημαντικότητας, και οι προβλεπτικές μετρικές φέρουν bootstrap διαστήματα εμπιστοσύνης — κάτι που ξεχωρίζει τα πραγματικά φαινόμενα από την τύχη ενός μόνο split.
- Ένα ελεγχόμενο, like-for-like benchmark τριών minority oversamplers — ενός υβριδικού Tabular VAE, ενός Tabular DDPM diffusion μοντέλου, και του κλασικού SMOTE — κάτω από έναν κοινό evaluator. Το ειλικρινές συμπέρασμα είναι ότι σε αυτό το cohort μέτριας ανισορροπίας κανένας δεν βελτιώνει το downstream F1 έναντι του baseline· το μόνο σταθερό κέρδος του diffusion μοντέλου είναι στο να ταιριάζει τη διασπορά (spread) των synthetic χαρακτηριστικών (υποδιπλασιάζει την ασυμφωνία τυπικής απόκλισης, $p = 0.002$), αλλά αυτό αντισταθμίζεται από μια εξίσου σημαντική χειροτέρευση του μέσου, αφήνοντας το καθαρό σφάλμα ροπών αμετάβλητο. Τεκμηριώνουμε και διορθώνουμε την παγίδα categorical mode-collapse μέσω per-block categorical likelihoods — υλοποιημένων κατά τη δειγματοληψία με Gumbel-Softmax draws για το VAE και argmax snap για το diffusion μοντέλο [Jang et al. \(2017\)](#).
- Μια μελέτη αποδοτικότητας ετικετών που καλύπτει και τους δύο άξονες του προβλήματος — active learning (uncertainty sampling vs. random baseline vs. DQN agent) και self-labelling (μια πιστή επανυλοποίηση Co-Forest vs. Self-Training, τη μέθοδο που προτιμούν τα anchor papers). Το uncertainty υπερτερεί σταθερά του random ($p = 0.002$), ενώ ο RL agent — που αναφέρεται ειλικρινά — δεν ξεπερνά το heuristic σε αυτό το μέγεθος pool· και το self-labelling ανακτά το μεγαλύτερο μέρος του supervised F1 από 1–10% των ετικετών, αλλά νικά ένα supervised seed μόνο στο OULAD — μια αντιστροφή ανά cohort (Ενότητα 6.7).
- Μια in-processing ποινή fairness που ιχνηλατεί ένα εμπειρικό frontier accuracy–fairness: μειώνει σταθερά το demographic-parity χάσμα ($0.21 \rightarrow 0.08$ στο $\lambda=1$, $p = 0.002$) αλλά με πραγματικό κόστος ~ 1.6 μονάδων accuracy, και το σημείο λειτουργίας είναι ευαίσθητο στο seed.
- Ένα leakage-safe protocol multimodal σύντηξης (frozen DistilBERT + PCA μόνο στο train). Καθώς το dataset δεν έχει κείμενο, το δοκιμάζουμε σε simulated σχόλια, οπότε το κέρδος του αναφέρεται ως μεθοδολογική οροφή, όχι ως αναπτύξιμο αποτέλεσμα (Ενότητα 7.4).
- Ένα στρώμα αυστηρότητας και εντιμότητας πάνω σε όλη τη μελέτη: familywise-error έλεγχος (Holm/Bonferroni) που επιβεβαιώνει ότι τα headline ευρήματα επιβιώνουν των πολλαπλών συγκρίσεων· μια κλειστού τύπου ποσοτικοποίηση της οροφής του simulated κειμένου (0.28 bits πληροφορίας label, Ενότητα 6.11)· μια επικύρωση του protocol σε πραγματικό κείμενο έξι constructs στα Stanford MOOC posts· και μια επανεκτίμηση των σύγχρονων “multimodal-dropout” εργασιών, που δείχνουμε ότι στηρίζονται σε synthetic ή ιδιωτικό κείμενο (Ενότητα 6.12).
- Μια ενοποιημένη αφήγηση εντοπισμένων προκλήσεων (Ενότητα 7) που συνδέει κάθε σχεδιαστική επιλογή με τη συγκεκριμένη παγίδα που αντιμετωπίζει.

Τοποθέτηση σε σχέση με πρόσφατες εργασίες. Τα επιμέρους δομικά στοιχεία είναι καθιερωμένα παρά πρωτότυπα: τα generative μοντέλα (VAE και diffusion) για tabular και εκπαιδευτικά synthetic δεδομένα αποτελούν ενεργό πεδίο ([Kotelnikov et al., 2023](#); [Kostopoulos et al., 2025](#)), η δικαιότερη πρόβλεψη εγκατάλειψης διαθέτει ειδικές in-processing αρχιτεκτονικές όπως το adversarial debiasing ([Gao and Ni, 2025](#)), και multimodal μοντέλα εγκατάλειψης με πραγματικό ελεύθερο κείμενο υπάρχουν ήδη ([Zerkouk et al., 2025](#)). Η συνεισφορά μας επομένως δεν είναι μια νέα μέθοδος αλλά μια ολοκληρωμένη, ειλικρινά αξιολογημένη μελέτη: μια multi-seed, ελεγμένη ως προς τη σημαντικότητα, like-for-like σύγκριση αυτών των τεχνικών σε ένα ενιαίο cohort τρίτοβάθμιας εκπαίδευσης, στην οποία τα αρνητικά και εύθραυστα αποτελέσματα αναφέρονται εξίσου ξεκάθαρα με τα θετικά.

Αποκλίσεις από την αρχική πρόταση. Για διαφάνεια καταγράφουμε πού το παραδοτέο pipeline αποκλίνει από την αρχική πρόταση. (i) Η πρόταση όριζε Support Vector Machines και ensembles ως τα supervised baselines· εμείς αντ’ αυτού αναφέρουμε Random Forest, XGBoost, και ένα PyTorch MLP (το MLP λειτουργεί και ως ο ελεγχόμενος κορμός που επαναχρησιμοποιείται από τις generative, fairness, και multimodal φάσεις). (ii) Ο πυλώνας “semi-supervised” υλοποιείται μέσω generative minority augmentation (Φάσεις 3–4), pool-based active learning (Φάσεις 5–6), και ενός self-labelled SSL baseline (Co-Forest και Self-Training, Ενότητα 6.7)· δεν υλοποιήσαμε την *πλήρη* σουίτα self-labelled αλγορίθμων (π.χ. CoBC, Rel-Rasco) που αξιολογούν τα anchor papers, αλλά η σύγκριση Co-Forest καλύπτει τη μέθοδο που βρίσκουν ισχυρότερη. (iii) Το αίτημα της πρότασης για άμεση σύγκριση με έναν παραδοσιακό oversampler όπως το SMOTE καλύπτεται από τη Φάση 3b (Ενότητα 6.4). (iv) Η υλοποίηση χρησιμοποιεί scikit-learn, PyTorch, XGBoost, και HuggingFace transformers στη θέση του stack h2o/orange/libact/keras που σκιαγραφήσε η πρόταση, κάτι που δεν επηρεάζει καμία αναφερόμενη μετρική. Καμία από αυτές τις αλλαγές δεν μεταβάλλει τους τρεις βασικούς πυλώνες του project: generative augmentation, label-efficient learning, και fairness.

1.3 Οργάνωση του εγγράφου

Η Ενότητα 2 ανασκοπεί τις τέσσερις αναφερόμενες εργασίες MDPI και τοποθετεί το pipeline μας στο ευρύτερο τοπίο EDM/ML. Η Ενότητα 3 περιγράφει το dataset και τη διερευνητική ανάλυση. Η Ενότητα 4 εισάγει την πλήρη μεθοδολογία με μαθηματική λεπτομέρεια για το VAE, το diffusion μοντέλο, τον DQN-based active learner, τη συνάρτηση απώλειας in-processing fairness, και τη multimodal σύντηξη. Η Ενότητα 5 αναφέρει το πειραματικό setup. Η Ενότητα 6 παρουσιάζει αποτελέσματα και συγκριτική ανάλυση. Η Ενότητα 7 είναι η αφιερωμένη αφήγηση εντοπισμένων προκλήσεων και μετριάσεων. Η Ενότητα 8 ολοκληρώνει και δείχνει μελλοντική εργασία. Αποσπάσματα κώδικα παρέχονται στο παράρτημα.

2 Ανασκόπηση Βιβλιογραφίας

Η μεθοδολογία αυτού του project βρίσκεται στη διασταύρωση πέντε ερευνητικών ρευμάτων: semi-supervised learning με generative augmentation, μοντελοποίηση denoising-diffusion για tabular δεδομένα, active learning βασισμένο σε reinforcement learning, in-processing αλγοριθμική δικαιοσύνη (fairness), και multimodal σύντηξη με transformer encoders. Ανασκοπούμε τις τέσσερις εργασίες MDPI που θα αναφέρουμε επανειλημμένα σε όλη αυτή την αναφορά, και έπειτα τοποθετούμε το pipeline μας έναντι του ευρύτερου τεχνικού τοπίου.

2.1 Συνθετικά δεδομένα για semi-supervised EDM (Kostopoulos et al., 2025)

Οι Kostopoulos et al. (2025) εξετάζουν πώς να καταστεί το semi-supervised learning (SSL) βιώσιμο στο EDM, όπου ο λόγος labelled δεδομένων είναι συστηματικά κάτω από δέκα τοις εκατό. Η συνεισφορά τους είναι το παράδειγμα TVAE-SSL: εκπαιδεύεται ένα Tabular Variational Autoencoder Kingma and Welling (2014) αποκλειστικά στο labelled κλάσμα, δειγματοληπτείται ένα synthetic, unlabelled pool από το εκπαιδευμένο TVAE, και έπειτα τροφοδοτούνται τόσο τα πραγματικά όσο και τα synthetic unlabelled σύνολα σε έναν self-labelling SSL αλγόριθμο όπως το Self-Training ή το Co-training by Committee. Αξιολογημένο σε τέσσερα EDM datasets (cert, eap2024, MBA, student) με accuracy, F1, και τις αποκλίσεις demographic-parity και equalised-odds, το framework τους ανακτά σχεδόν-supervised accuracy στο cert (πάνω από 0.94 ακόμη και στο 1–5% ετικετών) και ανεβάζει το imbalanced student dataset σε 0.87 accuracy (CoBC) και F1 πάνω από 0.83 (Rel-Rasco). Κρισίμως, η ίδια η συζήτησή τους τονίζει ότι τα κέρδη fairness είναι *συγκεντρωμένα στο low-label καθεστώς* — όπου τα synthetic δείγματα αντισταθμίζουν το bias του αραιού συνόλου — και ότι “η επάρκεια ετικετών από μόνη της δεν εγγυάται fairness,” με τις αποκλίσεις ενίοτε να χειροτερεύουν καθώς προστίθενται ετικέτες (bias amplification). Αυτή η εξάρτηση-από-το-καθεστώς είναι το κλειδί για τη συμφιλίωση της εργασίας τους με τη δική μας Φάση 7 παρακάτω.

Για το project μας αυτή η εργασία είναι ο άμεσος διανοητικός πρόδρομος της Φάσης 3 (ο VAE oversampler), και τα αποτελέσματά μας *συμφωνούν* μαζί της με τρόπο που αξίζει να γίνει ρητός: η δική τους άμεση σύγκριση TVAE-augmented SSL έναντι απλού SSL (ο Πίνακάς τους 18) δίνει μόνο οριακές — και ενίοτε αρνητικές — μεταβολές accuracy, που είναι ακριβώς το αποτέλεσμα “οι generative oversamplers ισοβαθμούν στο downstream F1” που αναφέρουμε στην Ενότητα 7.1. Υιοθετούμε δύο από τις σχεδιαστικές τους επιλογές — TVAE-style ανά-στήλη (hybrid) likelihoods για μικτά αριθμητικά/categorical δεδομένα, και την από κοινού αναφορά προβλεπτικών και fairness μετρικών — αλλά η δική μας *χρήση* του generator διαφέρει σκόπιμα. Το TVAE-SSL εκπαιδεύει τον autoencoder σε *ολόκληρο* το labelled σύνολο και έπειτα *απορρίπτει τις ετικέτες*, εισάγοντας τις synthetic γραμμές ως επιπλέον *unlabelled* δεδομένα για έναν self-labelling SSL αλγόριθμο· εμείς αντ’ αυτού εκπαιδεύουμε τον generator *μόνο στη μειοψηφική κλάση* και κρατάμε τις ετικέτες της, χρησιμοποιώντας τις synthetic γραμμές ως labelled oversampling (πιο κοντά στο πνεύμα του SMOTE). Έπειτα προχωράμε πέρα από τους Kostopoulos et al. σε δύο άξονες που οι ίδιοι ονομάζουν ως future work: (i) αντικαθιστούμε το VAE με ένα diffusion μοντέλο στη Φάση 4 — η καταληκτική τους ενότητα ρητά επισημαίνει το “GAN-based ή diffusion-based” augmentation ως υποσχόμενο επόμενο βήμα, και το diffusion διατηρεί πιο πιστά τις tabular κατανομές [Kotelnikov et al. \(2023\)](#) — και (ii) προσθέτουμε uncertainty- και RL-driven acquisition στις Φάσεις 5–6, απαντώντας στο κάλεσμά τους για “uncertainty-aware sample filtering ή confidence-weighted synthetic instance selection.” Στην πορεία λύνουμε την παθολογία *categorical mode-collapse* (Ενό τητα 4.2.1) που προκαλεί μια αφελής Gaussian likelihood πάνω σε one-hot blocks.

2.2 Self-labelled SSL για πρόβλεψη εγκατάλειψης σε MOOC ([Raftopoulos et al., 2025b](#))

Οι [Raftopoulos et al. \(2025b\)](#) αξιολογούν (benchmark) δέκα self-labelled SSL αλγορίθμους σε ένα πραγματικό MOOC dataset (μάθημα *DevOps Competences for Smart Cities*· 961 εγγραφές, 936 αναλυθείσες εγγραφές) υπό ακραία σπανιότητα ετικετών (2%, 3%, 4%). Δείχνουν ότι οι ensemble-based μέθοδοι, ιδίως το *Co-Forest* και το *Co-training by Committee (CoBC)*, ανακτούν σχεδόν-supervised accuracy με μόλις 2% των ετικετών: το *Co-Forest* φτάνει 0.910 accuracy στο 2%, με F1 έως 0.946 στα 3–4%, αποτελέσματα εντός τεσσάρων μονάδων από το πλήρως-supervised oracle. Τα συμπεράσματα που μας αφορούν είναι: (i) η διαφωνία του ensemble είναι ένα αξιοσημείωτα αποτελεσματικό σήμα pseudo-labelling στο πλαίσιο EDM· (ii) η επιθετική επεξεργασία pseudo-label (De-Tri-Training) είναι αντιπαραγωγική· και (iii) ένα μικρό labelled seed, καλά επιλεγμένο, μπορεί να επαρκεί. Η τελευταία παρατήρηση υποκινεί άμεσα τις φάσεις active-learning μας — το seed στα πειράματά μας είναι 40 δείγματα, περίπου 1.2% του training pool. Μια σημείωση εμβέλειας προκύπτει άμεσα: αυτή η εργασία (και η μελέτη TVAE-SSL παραπάνω) ακολουθεί τον άξονα *self-labelling* — αυτόματο pseudo-labelling των unlabelled σημείων — ενώ οι Φάσεις 5–6 μας ακολουθούν τον συμπληρωματικό άξονα *active-learning* της επιλογής *ποια* σημεία πρέπει να επισημάνει ένας άνθρωπος. Γι’ αυτό προσθέτουμε ένα δικό μας ισοδύναμο self-labelled baseline: η Ενότητα 6.7 υλοποιεί εκ νέου το *Co-Forest* — τη μέθοδο που αυτές οι εργασίες βρίσκουν ισχυρότερη — και το τρέχει, μαζί με το Self-Training, στα cohort μας υπό το ακριβές τους πρωτόκολλο label-scarcity.

2.3 Human-in-the-loop AI: ένα ενοποιημένο πλαίσιο σχεδίασης ([Lazaros et al., 2026](#))

Οι [Lazaros et al. \(2026\)](#) συνθέτουν 134 μελέτες για human-in-the-loop (HITL) AI σε μια τρισδιάστατη ταξινόμηση: (a) τοποθέτηση στο loop (in-, on-, over-, under-, και along-the-loop), (b) κοκκώδες της αλληλεπίδρασης (coarse / medium / fine), και (c) χρονικά χαρακτηριστικά (synchronous / asynchronous, episodic / continuous). Για τις τεχνικές μεθόδους καλύπτουν ρητά active learning, reinforcement learning from human feedback (RLHF), αλληλεπίδραση ανθρώπου-generative μοντέλου, και explainable AI. Δύο από τους “anchor tables” τους ενημερώνουν τις φάσεις active-learning μας. Πρώτον, το active learning αναγνωρίζεται ως οικονομικά αποδοτικό σε καθεστώτα μικρών δεδομένων αλλά ευάλωτο σε σπαταλημένα queries σε μη-πληροφοριακά ή πλεονάζοντα σημεία, όταν το score acquisition βασίζεται καθαρά σε uncertainty. Δεύτερον, οι πολιτικές RLHF και RL-based

acquisition επισημαίνονται ως ισχυρές αλλά εκτεθειμένες σε *reward hacking* όταν το σήμα ανταμοιβής δεν είναι ευθυγραμμισμένο με τον πραγματικό στόχο. Πήραμε στα σοβαρά αυτή την προειδοποίηση στη Φάση 6: η ανταμοιβή του DQN μας είναι το ανά-γύρο κέρδος σε F_1 , όχι σε accuracy, ακριβώς ώστε ο agent να μην μπορεί να διογκώσει την ανταμοιβή αποκτώντας εύκολα δείγματα της πλειοψηφικής κλάσης.

2.4 Fairness-aware ML: ένα ολοκληρωμένο benchmark (Raftopoulos et al., 2025a)

Οι Raftopoulos et al. (2025a) ανασκοπούν και αξιολογούν εμπειρικά δώδεκα in-processing fairness-aware αλγόριθμους (AdaFair, FairGBM, παραλλαγές Fairlearn, Prejudice Remover, κ.ο.κ.) σε επτά datasets, συμπεριλαμβανομένων των σχετικών με την εκπαίδευση benchmarks *Law School* και *MBA Admission*. Το κύριο συμπέρασμά τους — *καμία μεμονωμένη μέθοδος δεν κυριαρχεί* — είναι η εμπειρική δικαιολόγηση της δικής μας προσέγγισης να *σαρώνουμε την ισχύ regularisation* λ αντί να επιλέγουμε έναν μόνο fairness αλγόριθμο. Στο dataset *Adult* δείχνουν το FairGBM σε accuracy 0.874 με κακά scores απόκλισης έναντι του AdaFair σε accuracy 0.761 αλλά με μηδενική απόκλιση, που είναι ακριβώς το Pareto trade-off accuracy–fairness που αναπαράγουμε (σε μικρογραφία) στο dropout dataset στη Φάση 8. Δύο επιπλέον σημεία επαφής καθιστούν αυτή την εργασία την πλησιέστερη fairness αναφορά μας. Η συζήτησή τους ρητά συνιστά την ανάγνωση του fairness από *Pareto frontiers accuracy–fairness* (η §9.3 τους) — ακριβώς το artefact που παράγει η Φάση 8 μας — και ονομάζουν την *απουσία ενός sweep ευαισθησίας hyper-parameter*, με κάθε μοντέλο να τρέχει σε library defaults, ως τον κύριο περιορισμό του benchmark (η §9.1 τους). Το λ-sweep μας είναι άμεση απάντηση: μετατρέπει την εικόνα τους ενός-σημείου-ανά-μοντέλο σε ένα συνεχές, seed-bootstrapped frontier σε ένα πραγματικό dropout cohort.

2.5 Ευρύτερο τοπίο

Diffusion μοντέλα για tabular δεδομένα. Τα Denoising Diffusion Probabilistic Models (DDPMs) Ho et al. (2020); Sohl-Dickstein et al. (2015) έχουν εκτοπίσει ταχύτατα τα GANs και τα VAEs ως την αιχμή για high-fidelity παραγωγή στην όραση. Το TabDDPM Kotelnikov et al. (2023) προσαρμόζει το framework σε ετερογενή tabular δεδομένα, χρησιμοποιώντας Gaussian diffusion στα numerical χαρακτηριστικά και multinomial diffusion στα categorical, και αναφέρει ανώτερη κατανομική πιστότητα σε σχέση με το CTGAN Xu et al. (2019) και το TVAE σε καθιερωμένα benchmarks. Η Φάση 4 μας υλοποιεί ένα απλοποιημένο TabDDPM με μια κοινή (numerical + one-hot) Gaussian forward διαδικασία και έναν εκπαιδευμένο ϵ_θ denoiser, επαναφέροντας (snap) κάθε denoised categorical block σε έγκυρο one-hot με argmax κατά τη δειγματοληψία.

Active learning και RL-based acquisition. Το κλασικό pool-based active learning βασίζεται σε uncertainty Lewis and Gale (1994); Settles (2009) ή query-by-committee heuristics. Οι Fang et al. (2017) ήταν από τους πρώτους που αναδιατύπωσαν την πολιτική acquisition ως Markov decision process και τη μάθανε μέσω deep reinforcement learning, επιδεικνύοντας κέρδη έναντι του uncertainty sampling σε εργασίες NLP. Οι Ren et al. (2021) ανασκοπούν το ευρύτερο πεδίο “deep active learning”. Η Φάση 6 μας υλοποιεί ένα μικρό DQN Mnih et al. (2015) που επιλέγει ένα από είκοσι pool strata σε κάθε γύρο, εξαρτημένο από μια συμπαγή σύνοψη στατιστικών του pool, και χρησιμοποιεί το F1-gain ως ανταμοιβή.

Fairness στη supervised μάθηση. Η ταξινομία των παρεμβάσεων fairness διακρίνει μεθόδους *pre-, in-,* και *post-processing* Mehrabi et al. (2021). Τρεις σημαντικές in-processing διατυπώσεις στηρίζουν τη Φάση 8 μας: το convex πλαίσιο fairness-constraints των Zafar et al. (2017), το πλαίσιο reductions των Agarwal et al. (2018), και η έννοια equalised-odds των Hardt et al. (2016). Η Φάση 7 στο pipeline μας λειτουργεί ως ένας διαφανής post-hoc έλεγχος, υποκινώντας την in-processing παρέμβαση της Φάσης 8.

Multimodal μάθηση με BERT. Οι [Devlin et al. \(2019\)](#) εισήγαγαν το BERT ως έναν transformer-based αμφίδρομο encoder· οι [Sanh et al. \(2019\)](#) το απέσταξαν σε μια μικρότερη, 40% ταχύτερη παραλλαγή που χρησιμοποιείται σε παραγωγή. Η multimodal πρόβλεψη εγκατάλειψης έχει αρχίσει να αξιοποιεί τέτοιους encoders για να συντήξει αντικείμενα ελεύθερου κειμένου (forum posts, σημειώσεις καθοδήγησης) με tabular χαρακτηριστικά. Οι [Zerkouk et al. \(2025\)](#) αναφέρουν μια multimodal αρχιτεκτονική (“SentiDrop”) που συνδυάζει DistilBERT sentiment embeddings με tabular χαρακτηριστικά και επιτυγχάνει αξιοσημείωτες βελτιώσεις F1 έναντι tabular-only baselines σε δεδομένα εξ αποστάσεως εκπαίδευσης. Η Φάση 9 μας αναπαράγει το πνεύμα αυτής της αρχιτεκτονικής σε simulated feedback φοιτητών — μια σκόπιμη περιοριστική επιλογή εμβέλειας, καθώς το UCI dataset δεν περιέχει εγγενείς στήλες κειμένου.

3 Περιγραφή Συνόλου Δεδομένων & Διερευνητική Ανάλυση

3.1 Επισκόπηση του dataset

Χρησιμοποιούμε το UCI Predict Students’ Dropout and Academic Success dataset [Realinho et al. \(2022\)](#), ένα σύνολο εγγραφών τριτοβάθμιας εκπαίδευσης από την Πορτογαλία, αρχικά επιμελημένο από τους [Realinho et al. \(2022\)](#) και πλέον διανεμόμενο μέσω του UCI Machine Learning Repository. Το raw CSV περιέχει $n = 4,424$ γραμμές και 37 στήλες (36 προβλεπτικά χαρακτηριστικά συν την αρχική τρι-κλασική Target). Κάθε γραμμή είναι μία παρατήρηση φοιτητή καταγεγραμμένη στο τέλος του πρώτου ακαδημαϊκού έτους· η στήλη-στόχος Target είναι μία από τρεις κλάσεις — *Graduate*, *Dropout*, ή *Enrolled* (ακόμη εγγεγραμμένος, ούτε απόφοιτος ούτε εγκαταλείψας). Για αυτή τη μελέτη υιοθετούμε τη δυαδική διατύπωση της αρχικής πρότασης του project:

$$y = \mathbb{I}[\text{Target} = \text{Dropout}] \in \{0, 1\}. \quad (1)$$

Η προκύπτουσα κατανομή κλάσεων είναι ήπια ανισόρροπη: 3,003 μη-εγκαταλείψαντες (Graduate + Enrolled) έναντι 1,421 εγκαταλειψάντων, δηλαδή ρυθμός εγκατάλειψης 32.1%.

Σχήμα χαρακτηριστικών. Οι 36 προβλεπτικές στήλες χωρίζονται σε 18 nominal-categorical και 18 numerical-continuous χαρακτηριστικά. Οι categorical στήλες περιλαμβάνουν *Marital status*, *Application mode*, *Course*, *Nationality*, κωδικούς προσόντων και επαγγέλματος γονέων, *Gender*, *Scholarship holder*, και αρκετές δυαδικές σημαίες κατάστασης. Οι numerical στήλες περιλαμβάνουν *Admission grade*, *Age at enrolment*, στατιστικά curricular-unit δύο εξαμήνων (credited, enrolled, evaluated, approved, μέσος βαθμός), και μακροοικονομικούς δείκτες (ανεργία, πληθωρισμός, GDP).

Προστατευόμενο χαρακτηριστικό και χάσμα base-rate. Ακολουθώντας την πρόταση, ορίζουμε το *Gender* ως το δυαδικό προστατευόμενο χαρακτηριστικό. Ο εμπειρικός ρυθμός εγκατάλειψης διαφέρει έντονα μεταξύ των δύο ομάδων:


$$\begin{aligned} P(y = 1 \mid \text{Gender} = 0) &= 0.251, & n_0 &= 2,868, \\ P(y = 1 \mid \text{Gender} = 1) &= 0.451, & n_1 &= 1,556. \end{aligned} \quad (2)$$

Αυτό το χάσμα base-rate των 19.9 μονάδων είναι το άνω φράγμα του τι μπορεί να ελπίζει να μειώσει στο μηδέν ένας δίκαιος classifier (υπό demographic parity) χωρίς να αλλάξει τις προβλέψεις του στην πλειοψηφική περίπτωση, και παρέχει το κίνητρο για τις φάσεις fairness 7 και 8.


Ελλείπουσες τιμές. Το dataset περιέχει μηδέν ελλείπουσες τιμές σε όλες τις 37 στήλες — ιδιότητα της επιμελημένης διανομής UCI. Επομένως δεν χρειαστήκαμε μεθόδους imputation· αυτό επίσης αφαιρεί έναν πιθανό confounder κατά τη σύγκριση στρατηγικών generative augmentation.

3.2 Train / test split και one-hot επέκταση

Εκτελούμε ένα μοναδικό stratified 75/25 split (`random_state=42`): 3,318 γραμμές training και 1,106 γραμμές test. Αφού τυποποιήσουμε (`standardise`) τις 18 numerical στήλες με έναν `StandardScaler` προσαρμοσμένο μόνο στα training δεδομένα, και κάνουμε one-hot encoding τις 18 categorical στήλες με έναν encoder προσαρμοσμένο μόνο στα training δεδομένα, η διάσταση των encoded χαρακτηριστικών επεκτείνεται από 36 σε **247**. Η επέκταση κυριαρχείται από τις υψηλής cardinality στήλες `Course` (17 κατηγορίες), `Mother's occupation` (32), `Father's occupation` (46) και `Nationality` (21) (cardinalities μετρημένες στο πλήρες σύνολο, που θα έδινε $18 + 244 = 262$ encoded στήλες· ο encoder βλέπει μόνο τις κατηγορίες που εμφανίζονται στο 75% training split, εξ ου και 247).




(α') Ισορροπία κλάσεων — δυαδική διατύπωση.




(β') Ρυθμός εγκατάλειψης ανά φύλο.

Σχήμα 1: Διερευνητικά στιγμιότυπα του στόχου εγκατάλειψης (Φάση 1). Η μειοψηφική κλάση είναι αρκετά μεγάλη (32%) ώστε το `synthetic oversampling` να προσφέρει μόνο οριακά κέρδη `accuracy`· το χάσμα `base-rate` ανά φύλο, αντιθέτως, είναι αρκετά έντονο ώστε να κυριαρχεί στην ανάλυση `fairness`.



(α') Κατανομή ηλικίας κατά την εγγραφή.



(β') Heat-map συσχέτισης numerical χαρακτηριστικών.

Σχήμα 2: Επιπλέον EDA: η εγκατάλειψη είναι έντονα μετατοπισμένη προς μεγαλύτερους σε ηλικία φοιτητές (δεξιά ουρά), και οι μετρήσεις “`approved`” των `curricular-unit` είναι οι ισχυρότεροι μονο-χαρακτηριστικοί συσχετιστές του στόχου.

Σύνοψη ευρημάτων EDA.

- Η ανισορροπία κλάσεων είναι μέτρια (32% θετικά) — αρκετά ισχυρή ώστε οι classifiers να πρέπει να σταθμίζουν τη μειοψηφική κλάση, αλλά αρκετά ήπια ώστε το επιθετικό resampling να μην είναι αυστηρά απαραίτητο.
- Το χάσμα base-rate ανά φύλο είναι η κυρίαρχη πηγή αδικίας του μοντέλου. Το augmentation από μόνο του δεν το διορθώνει (Φάση 7): απαιτείται in-processing παρέμβαση (Φάση 8).
- Τα numerical χαρακτηριστικά δείχνουν σημαντική συσχέτιση — τα *Curricular units 2nd sem (approved)* συσχετίζονται $r \approx 0.90$ με τα *Curricular units 1st sem (approved)*, και οι μετρήσεις curricular-unit σχηματίζουν ένα έντονα collinear μπλοκ. Διατηρούμε παρ' όλα αυτά όλα τα χαρακτηριστικά: τα μοντέλα που χρησιμοποιούμε (tree ensembles, regularised linear/MLP) είναι ανθεκτικά στην collinearity για πρόβλεψη, και η αφαίρεση συσχετισμένων στηλών ακαδημαϊκής προόδου θα πετούσε σήμα — αλλά ερμηνείες σε επίπεδο συντελεστών ή importance μεμονωμένων curricular-unit χαρακτηριστικών πρέπει να διαβάζονται με αυτή την collinearity κατά νου.

4 Μεθοδολογία

Αυτή η ενότητα παρουσιάζει τις μαθηματικές διατυπώσεις κάθε συστατικού του pipeline. Ο συμβολισμός είναι ενιαίος: $\mathbf{x} \in \mathbb{R}^d$ δηλώνει ένα μεμονωμένο encoded διάνυσμα χαρακτηριστικών με $d = 247$, $y \in \{0, 1\}$ την ετικέτα εγκατάλειψης, και $s \in \{0, 1\}$ το προστατευόμενο (gender) χαρακτηριστικό. Το training set είναι $\mathcal{D}_{\text{tr}} = \{(\mathbf{x}_i, y_i, s_i)\}_{i=1}^{n_{\text{tr}}}$, $n_{\text{tr}} = 3,318$. το held-out test set είναι $\mathcal{D}_{\text{te}}$ με $n_{\text{te}} = 1,106$.

4.1 Baseline supervised learning (Φάση 2)

Εκπαιδεύουμε τρία discriminative μοντέλα στο encoded $\mathcal{D}_{\text{tr}}$.

Random Forest (RF). Ένα bagged ensemble από $T = 300$ Classification and Regression Trees [Breiman \(2001\)](#). Για μια είσοδο $\mathbf{x}$ το ensemble επιστρέφει

$$\hat{y}(\mathbf{x}) = \mathbb{I} \left[\frac{1}{T} \sum_{t=1}^T h_t(\mathbf{x}) \geq 0.5 \right],$$

με $h_t(\cdot)$ την πιθανότητα δυαδικής κλάσης του t -οστού δέντρου. Η υλοποίηση είναι το `sklearn.ensemble.RandomForestClassifier` με `class_weight="balanced"` και $\sqrt{d}$ feature bagging.

XGBoost. Gradient-boosted decision trees που ελαχιστοποιούν το regularised logistic objective [Chen and Guestrin \(2016\)](#)

$$\mathcal{L}_t^{\text{XGB}} = \sum_{i=1}^{n_{\text{tr}}} \ell(y_i, \hat{y}_i^{(t-1)} + f_t(\mathbf{x}_i)) + \Omega(f_t), \quad \Omega(f) = \gamma T_{\text{leaves}} + \frac{1}{2} \lambda \sum_j w_j^2, \quad (3)$$

όπου f_t είναι το t -οστό δέντρο και ℓ είναι binary cross-entropy. Χρησιμοποιούμε 400 γύρους, learning rate 0.08, μέγιστο βάθος 5, row- και column-subsampling 0.9, προεπιλεγμένο L2 regularisation $\lambda = 1$, και `scale_pos_weight` ορισμένο στον λόγο negative/positive του training.

Multi-Layer Perceptron (MLP). Ένας μικρός PyTorch feed-forward classifier με δύο hidden layers ($d \rightarrow 128 \rightarrow 64 \rightarrow 1$), ReLU activations, dropout $p = 0.2$, και μία logit έξοδο. Η training loss είναι

$$\mathcal{L}_{\text{BCE}}^{\text{MLP}}(\theta) = -\mathbb{E}_{(\mathbf{x}, y) \sim \mathcal{D}_{\text{tr}}} [y \log \sigma(z_{\theta}(\mathbf{x})) + (1 - y) \log(1 - \sigma(z_{\theta}(\mathbf{x})))], \quad (4)$$

με σ το logistic sigmoid και z_θ το logit του δικτύου. Βελτιστοποιούμε με Adam [Kingma and Ba \(2015\)](#) ($\text{lr} = 10^{-3}$, weight decay 10^{-5}) για 60 epochs με batch size 128. Η ίδια αρχιτεκτονική MLP επανα-χρησιμοποιείται στις Φάσεις 3, 4, 8, και 9 — αλλάζουν μόνο τα training δεδομένα ή η συνάρτηση απώλειας — ώστε οι συγκρίσεις να είναι architecture-controlled.

4.2 Generative data augmentation

Συζητάμε διαδοχικά το VAE (πρόταση) και το diffusion μοντέλο (Αναβάθμιση 1), και έπειτα ανα-δεικνύουμε την παγίδα categorical mode-collapse που τα ενοποιεί.

4.2.1 Tabular Variational Autoencoder (Φάση 3)

Ένα Tabular Variational Autoencoder [Kingma and Welling \(2014\)](#); [Kostopoulos et al. \(2025\)](#) μα-θαίνει μια latent αναπαράσταση $\mathbf{z} \in \mathbb{R}^{z_{\text{dim}}}$ τέτοια ώστε το δυσεπίλυτο evidence $p_\theta(\mathbf{x}) = \int p_\theta(\mathbf{x} | \mathbf{z}) p(\mathbf{z}) d\mathbf{z}$ να προσεγγίζεται μεγιστοποιώντας το *Evidence Lower Bound* (ELBO):

$$\mathcal{L}_{\text{ELBO}}(\mathbf{x}; \theta, \phi) = \underbrace{\mathbb{E}_{q_\phi(\mathbf{z}|\mathbf{x})}[\log p_\theta(\mathbf{x} | \mathbf{z})]}_{\text{reconstruction}} - \beta \cdot \underbrace{\text{KL}(q_\phi(\mathbf{z} | \mathbf{x}) \| p(\mathbf{z}))}_{\text{regulariser}}. \quad (5)$$

$p(\mathbf{z}) = \mathcal{N}(\mathbf{0}, \mathbf{I})$ είναι το prior και $q_\phi(\mathbf{z} | \mathbf{x}) = \mathcal{N}(\mu_\phi(\mathbf{x}), \sigma_\phi^2(\mathbf{x}) \mathbf{I})$ είναι το variational posterior.

Hybrid decoder για tabular δεδομένα. Το encoded διάνυσμα χαρακτηριστικών συνενώνει 18 standardised numerical συνιστώσες και 18 one-hot categorical blocks με cardinalities $\{c_k\}_{k=1}^{18}$ που αθροίζουν σε 229. Μια μονολιθική Gaussian likelihood στο $\mathbf{x}$ θα έσπρωχνε τα categorical blocks προς τον componentwise μέσο τους και θα παρήγαγε κλασματικές εξόδους που οι downstream classifiers δεν μπορούν να καταναλώσουν. Χρησιμοποιούμε επομένως έναν *hybrid decoder*:

- Gaussian likelihood στις $n_{\text{num}} = 18$ numerical συνιστώσες, με παράμετρο μέσου $\mu_{\text{num},\theta}(\mathbf{z}) \in \mathbb{R}^{18}$ και μοναδιαία διασπορά.
- Categorical likelihood σε κάθε one-hot block k μέσω ενός softmax head $g_{k,\theta}(\mathbf{z}) \in \Delta^{c_k-1}$.

Ο όρος reconstruction στην (5) αναλύεται ως

$$\log p_\theta(\mathbf{x} | \mathbf{z}) = -\frac{1}{2} \|\mathbf{x}_{\text{num}} - \mu_{\text{num},\theta}(\mathbf{z})\|_2^2 + \sum_{k=1}^{18} \log g_{k,\theta}(\mathbf{z})_{[\arg\max \mathbf{x}_{\text{cat},k}]}. \quad (6)$$

KL warm-up. Σε μικρά minority δεδομένα, ο όρος KL τείνει να κυριαρχεί στην απώλεια στις πρώ-τες epochs, προκαλώντας *posterior collapse*: $q_\phi(\mathbf{z} | \mathbf{x}) \rightarrow p(\mathbf{z})$ και ο decoder εκφυλίζεται στον μέσο των δεδομένων. Ακολουθώντας κοινή πρακτική, αυξάνουμε γραμμικά (warm up) τον συντελεστή KL από $\beta = 0$ σε $\beta_{\text{max}} = 1$ στις πρώτες 40 epochs.

Gumbel-Softmax sampling. Η δειγματοληψία νέων minority παραδειγμάτων απαιτεί την υλο-ποίηση hard one-hot διανυσμάτων από τα softmax heads $g_{k,\theta}(\mathbf{z})$. Το να παίρναμε πάντα το $\arg \max$ θα εξέπεμπε την επικρατέστερη κατηγορία κάθε block και θα πετούσε την εντός-block ποικιλομορ-φία που έχει μάθει ο decoder· αντ' αυτού *δειγματοληπτούμε* μια κατηγορία ανά block. Η κατασκευή *Gumbel-Softmax* [Jang et al. \(2017\)](#); [Maddison et al. \(2017\)](#) υλοποιεί ένα τέτοιο draw ορίζοντας

$$\tilde{y}_j = \frac{\exp((\log \pi_j + g_j)/\tau)}{\sum_k \exp((\log \pi_k + g_k)/\tau)}, \quad g_k \stackrel{\text{iid}}{\sim} \text{Gumbel}(0, 1), \quad (7)$$

όπου π_j είναι οι softmax πιθανότητες και τ είναι μια temperature· με `hard=True` το draw υλοποιεί-ται ως ακριβές one-hot. Στο pipeline μας αυτό είναι καθαρά μια *συσκευή δειγματοληψίας κατά την*

παράγωγη, εκτελούμενη υπό `no_grad`: κανένα gradient δεν ρέει ποτέ μέσα από αυτήν, και η εκπαίδευση δεν την αγγίζει. Αυτό που πραγματικά επιλύει την παθολογία categorical mode-collapse — ο διανοητικός πυρήνας της Φάσης 3 — είναι το *hybrid likelihood*: ένα cross-entropy head ανά categorical block, εκπαιδευμένο σε logits, με το Gumbel-Softmax να υλοποιεί έπειτα έγκυρα, στοχαστικά one-hots από αυτά τα εκπαιδευμένα heads όταν αντλούνται synthetic γραμμές. (Η straight-through διαφορισιμότητα της κατασκευής θα είχε σημασία μόνο αν η δειγματοληψία βρισκόταν μέσα στον training loop, που εδώ δεν ισχύει.)

4.2.2 Tabular Denoising Diffusion (Φάση 4, Αναβάθμιση 1)

Forward process. Ορίζουμε μια T -βηματική Markov chain που σταδιακά καταστρέφει μια είσοδο $\mathbf{x}_0$ με Gaussian θόρυβο [Sohl-Dickstein et al. \(2015\)](#); [Ho et al. \(2020\)](#):

$$q(\mathbf{x}_t | \mathbf{x}_{t-1}) = \mathcal{N}(\mathbf{x}_t; \sqrt{1 - \beta_t} \mathbf{x}_{t-1}, \beta_t \mathbf{I}), \quad t = 1, \dots, T. \quad (8)$$

Χρησιμοποιούμε ένα γραμμικό β -schedule με $\beta_1 = 10^{-4}$, $\beta_T = 2 \times 10^{-2}$ και $T = 200$. Ορίζοντας $\alpha_t = 1 - \beta_t$ και $\bar{\alpha}_t = \prod_{s \leq t} \alpha_s$, το closed-form noised δείγμα είναι

$$\mathbf{x}_t = \sqrt{\bar{\alpha}_t} \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t} \boldsymbol{\varepsilon}, \quad \boldsymbol{\varepsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}). \quad (9)$$

Reverse process και training loss. Παραμετροποιούμε τον μέσο του reverse-step με ένα residual MLP $\varepsilon_\theta(\mathbf{x}_t, t)$ με sinusoidal time embedding, δύο residual blocks πλάτους 256, και SiLU activations. Ακολουθώντας τους [Ho et al. \(2020\)](#), η εκπαίδευση ελαχιστοποιεί το απλοποιημένο MSE objective

$$\mathcal{L}^{\text{DDPM}}(\theta) = \mathbb{E}_{t, \mathbf{x}_0, \boldsymbol{\varepsilon}} \left[\left\| \boldsymbol{\varepsilon} - \varepsilon_\theta(\sqrt{\bar{\alpha}_t} \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t} \boldsymbol{\varepsilon}, t) \right\|_2^2 \right]. \quad (10)$$

Το sinusoidal time embedding είναι, για διάσταση embedding $d_t = 64$, $i = 0, \dots, d_t/2 - 1$,

$$\text{PE}(t)_{2i} = \sin(t \cdot \omega_i), \quad \text{PE}(t)_{2i+1} = \cos(t \cdot \omega_i), \quad \omega_i = \exp(-i \log 10^4 / (d_t/2)). \quad (11)$$

Ancestral sampling. Synthetic δείγματα παράγονται αρχικοποιώντας $\mathbf{x}_T \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ και επαναλαμβάνοντας, για $t = T, \dots, 1$,

$$\mathbf{x}_{t-1} = \frac{1}{\sqrt{\alpha_t}} \left(\mathbf{x}_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \varepsilon_\theta(\mathbf{x}_t, t) \right) + \sigma_t \mathbf{z}, \quad \mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}), \quad (12)$$

με $\sigma_t = \sqrt{\beta_t}$ (χωρίς learnt variance) και $\mathbf{z} = \mathbf{0}$ στο $t = 1$. Αφού φτάσουμε στο $\mathbf{x}_0$ επαναφέρουμε (snap) κάθε one-hot block στην επικρατέστερη κατηγορία του με *argmax* — ντετερμινιστική προβολή, το ίδιο snap που εφαρμόζει το SMOTE baseline. Το VAE διαφέρει σκόπιμα εδώ: ο decoder του εκπέμπει πραγματικά logits, που νομίμως δειγματοληπτούνται με Gumbel-Softmax, ενώ το denoised diffusion block προσεγγίζει ένα one-hot, όχι logits — αν το τροφοδοτούσαμε σε Gumbel-Softmax θα αντλούσε σχεδόν-ομοιόμορφες κατηγορίες στα blocks υψηλής cardinality (στο $\tau = 0.5$ η επικρατέστερη συντεταγμένη φέρει βάρος e^2 έναντι $K-1$ άλλων). Χωρίς κάποιο snap, αρκετές “categorical” συντεταγμένες προκύπτουν αρνητικές ή κλασματικές και σπάνε τους tree-based classifiers downstream.

4.2.3 Γιατί έχει σημασία η αναβάθμιση: κατανομική πιστότητα

Ένα κρίσιμο εμπειρικό ερώτημα είναι κατά πόσο το diffusion μοντέλο όντως αναπαράγει την κατανομή των πραγματικών δεδομένων καλύτερα από το VAE. Το μετράμε μέσω της μέσης ανά χαρακτηριστικό απόλυτης απόκλισης στον numerical μέσο και την τυπική απόκλιση:

$$\Delta_\mu = \frac{1}{n_{\text{num}}} \sum_{j=1}^{n_{\text{num}}} |\hat{\mu}_j^{\text{real}} - \hat{\mu}_j^{\text{synth}}|, \quad \Delta_\sigma = \frac{1}{n_{\text{num}}} \sum_{j=1}^{n_{\text{num}}} |\hat{\sigma}_j^{\text{real}} - \hat{\sigma}_j^{\text{synth}}|. \quad (13)$$

Θα δούμε (Ενότητα 6) ότι το diffusion μοντέλο υποδιπλασιάζει το Δ_σ σε σχέση με το VAE, με ελεγχόμενη αύξηση στο Δ_μ .

4.2.4 Κλασικό baseline: SMOTE oversampling (Φάση 3b)

Για να κρίνουμε τους δύο generative oversamplers έναντι μιας μη-generative αναφοράς, προσθέτουμε την κλασική Synthetic Minority Over-sampling Technique (Chawla et al., 2002). Το SMOTE συνθέτει μια minority γραμμή παρεμβάλλοντας μεταξύ ενός τυχαίου minority σημείου και ενός από τους k πλησιέστερους minority γείτονές του ($k = 5$), εξισορροπώντας το training set στο ίδιο μέγεθος με τα VAE- και diffusion-augmented σύνολα. Η παρεμβολή στον encoded χώρο παράγει κλασματικές τιμές μέσα σε κάθε one-hot block, οπότε επαναφέρουμε (snap) κάθε categorical block σε ένα έγκυρο one-hot με μια argmax προβολή – το ίδιο snap που εφαρμόζει ο diffusion sampler, και την ίδια τελική κατάσταση έγκυρων one-hot που φτάνει το VAE δειγματοληπτώντας τα decoder logits του – και έπειτα αξιολογούμε και τα τρία augmented σύνολα μέσω του πανομοιότυπου RF/XGBoost/MLP pipeline (phase3.evaluate_augmented). Αυτό απομονώνει την επίδραση μόνο της στρατηγικής augmentation, και παρέχει την άμεση σύγκριση SMOTE που ζητούσε η αρχική πρόταση.

4.3 Active learning

Οι φάσεις active-learning προσομοιώνουν έναν περιορισμένο προϋπολογισμό ετικετών. Ξεκινάμε με ένα μικροσκοπικό stratified seed L_0 από 40 δείγματα και ένα pool U από 3,278 unlabelled training γραμμές, και προχωράμε για $R = 25$ γύρους acquisition, καθένας ζητώντας $q = 20$ νέες ετικέτες. Ο συνολικός προϋπολογισμός ετικετών είναι επομένως $40 + 25 \times 20 = 540$ δείγματα (16.3% του training pool).

4.3.1 Uncertainty sampling (Φάση 5)

Στον γύρο r , προσαρμόζουμε μια logistic regression f_{θ_r} στο τρέχον labelled set L_r και κάνουμε query το unlabelled σημείο με μέγιστη Shannon entropy:

$$\mathbf{x}^* = \arg \max_{\mathbf{x} \in U} H(p_{\theta_r}(\cdot | \mathbf{x})) = - \sum_{c \in \{0,1\}} p_{\theta_r}(c | \mathbf{x}) \log p_{\theta_r}(c | \mathbf{x}). \quad (14)$$

Τη συγκρίνουμε με ένα random acquisition baseline που χρησιμοποιεί το ίδιο seed και προϋπολογισμό.

4.3.2 Reinforcement-learning acquisition (Φάση 6, Αναβάθμιση 2)

Διατυπώνουμε την απόφαση acquisition ως ένα Markov Decision Process (MDP) $\mathcal{M} = (\mathcal{S}, \mathcal{A}, P, \rho, \gamma)$:

- **State** $\mathbf{s}_r \in \mathbb{R}^{20}$. Για κάθε unlabelled σημείο υπολογίζουμε έναν 5-D candidate descriptor

$$\phi(\mathbf{x}) = (H(p(\cdot | \mathbf{x})), 1 - |2p(1 | \mathbf{x}) - 1|, \|\mathbf{x} - \bar{\mathbf{x}}_L\|_2, p(1 | \mathbf{x}), \min_{\tilde{\mathbf{x}} \in L'} \|\mathbf{x} - \tilde{\mathbf{x}}\|_2) \in \mathbb{R}^5$$

που αποτυπώνει entropy, margin, απόσταση από το labelled centroid, προβλεπόμενη minority πιθανότητα, και nearest-neighbour απόσταση σε ένα sub-sample $L' \subseteq L$ μεγέθους 120. Το state είναι τότε η συνένωση του ανά-χαρακτηριστικό mean, std, max, και 90% quantile σε όλο το pool:

$$\mathbf{s}_r = [\bar{\phi}, \sigma_{\phi}, \max_U \phi, q_{0.9}(\phi)] \in \mathbb{R}^{20}.$$

- **Action** $a_r \in \{0, \dots, 19\}$. Διακριτοποιούμε το acquisition διαμερίζοντας το pool σε 20 strata: 5 features $\times$ 4 quantile buckets. Η action $a_r = 4j + b$ επιλέγει το bucket b του feature j . Τα $q = 20$ δείγματα που γίνονται query στον γύρο r λαμβάνονται από αυτό το bucket.
- **Reward** ρ_r . $\rho_r = F_1^{(r)} - F_1^{(r-1)}$, η βελτίωση στο test-set F_1 μετά την απόκτηση αυτού του batch. Κρίσιμως, η accuracy **δεν** χρησιμοποιείται ως reward: η human-in-the-loop βιβλιογραφία Lazaros et al. (2026) επισημαίνει ότι μια accuracy-based reward δίνει κίνητρο στον agent να αποκτά εύκολα majority σημεία και να διογκώνει την accuracy χωρίς να βελτιώνει το recall στη minority

κλάση. Γνωστοποιούμε μια σκόπιμη απλούστευση: η reward υπολογίζεται στο held-out *test* set (και η greedy policy αξιολογείται έπειτα στο ίδιο set), οπότε το training σήμα του agent αγγίζει τα δεδομένα αξιολόγησης. Μια πραγματική ανάπτυξη θα έπρεπε αντ' αυτού να κόψει ένα validation fold από το pool για τη reward. Επειδή ο agent παρ' όλα αυτά *υπολείπεται* του uncertainty heuristic, αυτό το leakage είναι συντηρητικό ως προς το συμπέρασμά μας — μόνο να κολάκευσε τον RL agent μπορεί.

- **Policy.** Ένα μικρό Q-network $Q_\theta : \mathbb{R}^{20} \rightarrow \mathbb{R}^{20}$ (3-layer MLP, hidden width 64) εκπαιδευμένο με experience replay και μια ε -greedy behaviour policy της οποίας ο ρυθμός exploration φθίνει γραμμικά από ≈ 0.42 σε ένα κατώφλι 0.05 κατά τη διάρκεια των έξι episodes.

Ο Bellman target είναι το τυπικό one-step temporal-difference update [Sutton and Barto \(2018\)](#); [Mnih et al. \(2015\)](#):

$$Q^*(\mathbf{s}, a) = \mathbb{E} \left[\rho + \gamma \max_{a'} Q^*(\mathbf{s}', a') \mid \mathbf{s}, a \right], \quad (15)$$

υλοποιημένο ως μια Huber-loss regression του $Q_\theta(\mathbf{s}, a)$ προς το $\rho + \gamma \max_{a'} Q_\theta(\mathbf{s}', a')$, bootstrapped από το *ίδιο* online network (αυτή η ελαφριά υλοποίηση δεν χρησιμοποιεί ξεχωριστό target network) σε ομοιόμορφα δειγματοληπτημένα replay mini-batches. Εκπαιδεύουμε για $E = 6$ episodes (κάθε ένα είναι μια πλήρης AL trajectory) και αναφέρουμε την greedy policy σε ένα held-out seed.

4.4 Fairness-aware μάθηση

4.4.1 Fairness metrics

Για δυαδικό $y, \hat{y} \in \{0, 1\}$, και προστατευόμενο $s \in \{0, 1\}$ αναφέρουμε τις τυπικές group-fairness αποκλίσεις:

$$\Delta_{DP} = |P(\hat{y} = 1 \mid s = 1) - P(\hat{y} = 1 \mid s = 0)|, \quad (16)$$

$$\Delta_{EO} = |\text{TPR}_{s=1} - \text{TPR}_{s=0}|, \quad (17)$$

$$\Delta_{EqOdds} = \max(|\Delta \text{TPR}|, |\Delta \text{FPR}|). \quad (18)$$

Χαμηλότερο = δικαιότερο. Η Φάση 7 τις ελέγχει σε κάθε classifier των Φάσεων 2–4· η Φάση 8 τις μειώνει ενεργά.

4.4.2 In-processing demographic-parity penalty (Φάση 8, Αναβάθμιση 3)

Επαυξάνουμε την MLP loss με ένα διαφορίσιμο surrogate του Δ_{DP} :

$$\mathcal{L}^{\text{fair}}(\theta) = \mathcal{L}_{\text{BCE}}^{\text{MLP}}(\theta) + \lambda \left| \mathbb{E}_{\mathbf{x} \sim p(\mathbf{x}|s=1)}[\sigma(z_\theta(\mathbf{x}))] - \mathbb{E}_{\mathbf{x} \sim p(\mathbf{x}|s=0)}[\sigma(z_\theta(\mathbf{x}))] \right|. \quad (19)$$

Οι προσδοκίες (expectations) εκτιμώνται σε κάθε mini-batch και η απόλυτη διαφορά γίνεται back-propagated. Σαρώνουμε $\lambda \in \{0, 0.1, 0.5, 1, 2, 5, 10\}$ ώστε να ιχνηλατήσουμε το εμπειρικό Pareto frontier accuracy / Δ_{DP} .

Πρακτικές παγίδες.

- **Mini-batches με ελλείπουσα ομάδα.** Αν ένα mini-batch περιέχει μόνο μία προστατευόμενη ομάδα, το surrogate είναι μη-ορισμένο· παραλείπουμε τη συνεισφορά της ποινής σε εκείνο το βήμα.
- **Ασυμφωνία surrogate vs. hard-metric.** Το διαφορίσιμο surrogate χρησιμοποιεί $\sigma(z)$ στο $[0, 1]$ · το πραγματικό Δ_{DP} χρησιμοποιεί hard 0/1 προβλέψεις. Καθώς το λ μεγαλώνει το soft surrogate φθίνει ομαλά αλλά το hard Δ_{DP} μπορεί να ταλαντώνεται· αναφέρουμε επομένως και τα δύο και παράγουμε το Pareto frontier από το εμπειρικό hard-decision Δ_{DP} .

4.5 Multimodal επέκταση (Φάση 9, Αναβάθμιση 4)

Το UCI dataset δεν έχει εγγενείς στήλες κειμένου, οπότε προσομοιώνουμε ένα σχόλιο feedback ελεύθερου κειμένου ανά φοιτητή. Η παραγωγή σχολίου είναι ντετερμινιστική δεδομένων των (i, y_i) μέσω ενός salted MD5 hash, με τρία templated tone pools (positive / neutral / negative) των οποίων το μείγμα εξαρτάται από το αποτέλεσμα — οι εγκαταλείψαντες κλίνουν αρνητικά· οι μη-εγκαταλείψαντες κλίνουν θετικά, αλλά με ένα σκόπιμα θορυβώδες μείγμα ώστε το κείμενο να μην προδίδει την ετικέτα.

DistilBERT encoding. Χρησιμοποιούμε ένα frozen, pre-trained DistilBERT [Sanh et al. \(2019\)](#) (distilbert-base) το θ_{BERT} δεν ενημερώνεται ποτέ). Κάθε σχόλιο c_i tokenised, truncated σε μήκος 48, batched (32) και forwarded:

$$\mathbf{h}_i = \text{mean-pool}(\text{DistilBERT}_{\theta_{\text{BERT}}}(c_i)) \in \mathbb{R}^{768}. \quad (20)$$

Έπειτα μειώνουμε τη διαστατικότητα με PCA:

$$\mathbf{e}_i = W_{\text{PCA}} (\mathbf{h}_i - \mu_{\text{PCA}}) \in \mathbb{R}^{32}, \quad (21)$$

με τα $W_{\text{PCA}}, \mu_{\text{PCA}}$ προσαρμοσμένα μόνο στα training embeddings, και έπειτα standardised από έναν scaler προσαρμοσμένο μόνο στα training PCs. Το multimodal διάνυσμα χαρακτηριστικών είναι η συνένωση $\tilde{\mathbf{x}}_i = [\mathbf{x}_i; \mathbf{e}_i] \in \mathbb{R}^{279}$.

Αποφυγή leakage. Το πιο κοινό σφάλμα σε multimodal/transformer-augmented tabular pipelines είναι το fine-tuning του encoder σε ολόκληρο το corpus, που επιτρέπει στο κείμενο των test γραμμών να επηρεάσει την αναπαράσταση των training γραμμών. Δεν κάνουμε fine-tuning. Επίσης προσαρμόζουμε το PCA και τον scaler αποκλειστικά σε *training* embeddings, και ποτέ δεν καλούμε τον tokenizer με test κείμενο κατά την εκπαίδευση. Αυτές οι δικλίδες είναι standard πρακτική αποτροπής leakage για pipelines με pretrained encoders.

5 Πειραματική Διάταξη

5.1 Υλικό και λογισμικό

Όλα τα πειράματα εκτελέστηκαν σε μία CPU μηχανή (χωρίς GPU). Το Python περιβάλλον χρησιμοποιεί Python 3.13, numpy 2.2, pandas 2.2, scikit-learn 1.7 [Pedregosa et al. \(2011\)](#), xgboost 3.2 [Chen and Guestrin \(2016\)](#), PyTorch 2.12 για τα VAE / DDPM / DQN / fair-MLP, transformers 5.8 για το DistilBERT [Sanh et al. \(2019\)](#), imbalanced-learn 0.14 για το SMOTE baseline, και matplotlib 3.10+ seaborn 0.13 για τα plots. Όλη η τυχαιότητα είναι seeded (numpy, torch, scikit-learn random states) με RANDOM_SEED = 42 εξ ορισμού· η μελέτη multi-seed (Ενότητα 5.4) το σαρώνει μέσω μιας environment variable.

5.2 Αναπαραγώγιμο pipeline

Το pipeline χωρίζεται σε δέκα σύντομα scripts κάτω από τον φάκελο code/· οι διαδρομές αναλύονται σχετικά με τη ρίζα του repository (το raw CSV είναι εξ ορισμού ../data.csv, με δυνατότητα override μέσω της environment variable RAW_CSV). Κάθε script γράφει ένα JSON artefact στο results/, αποθηκεύει τυχόν μοντέλα ή synthetic δεδομένα στο data/, και σώζει PNG figures στο figures/. Ο Πίνακας 1 συνοψίζει τον χάρτη φάσεων.

Φάση	Στόχος	Κύριες έξοδοι
1. phase1_preprocessing.py	EDA, δυαδική διατύπωση, train/test split, one-hot & scaling.	processed.npz, EDA figures.
2. phase2_baselines.py	Εκπαίδευση RF, XGBoost, MLP στο encoded $\mathbf{X}_{tr}$.	ROC curves, confusion matrices, JSON μετρικές.
3. phase3_vae.py	Hybrid Tabular VAE oversampler στη μείωση-φία.	Synthetic vae_synth.npz, training curve.
4. phase4_diffusion.py	TabDDPM-style diffusion oversampler (Αναβάθμιση 1).	diffusion_synth.npz, σύγκριση real/synth.
5. phase5_uncertainty_AL.py	Entropy-based uncertainty AL vs random.	Learning curves 25 γύρων.
6. phase6_rl_AL.py	DQN-based RL active learner (Αναβάθμιση 2).	Learning curve RL vs uncertainty.
7. phase7_fairness_posthoc.py	Post-hoc έλεγχος fairness των μοντέλων P2/P3/P4.	Πίνακας αποκλίσεων, fairness-bar plot.
8. phase8_fairness_inprocess.py	In-processing demographic-parity penalty (Αναβάθμιση 3).	λ -sweep, Pareto frontier.
9. phase9_multimodal_bert.py	DistilBERT + tabular multimodal (Αναβάθμιση 4).	279-D multimodal scores.
10. phase10_master_comparison.py	Συγκέντρωση όλων των φάσεων.	master_comparison.csv, experiment_summary.md.

Πίνακας 1: Αναπαραγωγίμο pipeline δέκα φάσεων. Κάθε script τρέχει απομονωμένα και εξαρτάται μόνο από τα artefacts που παρήγαγαν προηγούμενες φάσεις.

5.3 Πρωτόκολλο αξιολόγησης

Όλες οι προβλεπτικές και fairness μετρικές υπολογίζονται στο held-out test set $\mathcal{D}_{te}$ ($n_{te} = 1,106$). Το train/test split είναι σταθερό για όλη τη μελέτη ώστε όλες οι συγκρίσεις να γίνονται έναντι ενός πανομοιότυπου evaluation cohort. Από άκρη σε άκρη το pipeline τρέχει σε περίπου πεντέμισι λεπτά σε μία σύγχρονη CPU (χωρίς GPU)· η φάση DQN active-learning (≈ 95 s) και το DistilBERT encoding των 4,424 σχολίων (≈ 50 s, μετά από ένα εφάπαξ κατέβασμα του μοντέλου) είναι τα βαρύτερα βήματα.

5.4 Πρωτόκολλο αξιοπιστίας multi-seed

Αρκετές φάσεις είναι στοχαστικές – το VAE, το diffusion μοντέλο, το fair-MLP και το DQN εξαρτώνται όλα από την τυχαία αρχικοποίηση, και το ίδιο το stratified split εξαρτάται από το seed – οπότε μία μεμονωμένη εκτέλεση δεν μπορεί να διαχωρίσει ένα πραγματικό φαινόμενο από την τύχη του seed. Επαναλαμβάνουμε επομένως ολόκληρο το pipeline για δέκα seeds. Κάθε seed επάγει ένα νέο stratified 75/25 split και νέα αρχικοποίηση μοντέλου, καθιστώντας το πρωτόκολλο μια ten-fold Monte-Carlo cross-validation που μεταβάλλει μαζί το evaluation cohort και την τυχαιότητα της βελτιστοποίησης. Το seed εισάγεται μέσω μιας μοναδικής environment variable που διαβάζει το κοινό module, οπότε ο κώδικας των φάσεων είναι byte-for-byte πανομοιότυπος μεταξύ εκτελέσεων. Για κάθε κύρια σύγκριση αναφέρουμε τον μέσο $\pm$ τυπική απόκλιση στα δέκα seeds και ένα paired δίπλευρο Wilcoxon signed-rank test στα ανά-seed ζεύγη (το ίδιο seed και στις δύο πλευρές), το κατάλληλο μη-παραμετρικό τεστ για $n = 10$ matched παρατηρήσεις. Επειδή το split μεταβάλλεται, η διάσταση των encoded χαρακτηριστικών διαφέρει ελαφρώς μεταξύ seeds (247–253, ανάλογα με το ποιες σπάνιες high-cardinality κατηγορίες πέφτουν στο training partition)· αυτό είναι εσωτερικό κάθε εκτέλεσης και δεν επηρεάζει καμία αναφερόμενη μετρική.

5.5 Bootstrap διαστήματα εμπιστοσύνης

Το πρωτόκολλο multi-seed αποτυπώνει τη διακύμανση από το split και τη βελτιστοποίηση. Ορθώγωνα, το μοναδικό held-out test set ($n_{te} = 1,106$) φέρει τη δική του δειγματοληπτική αβεβαιότητα. Για τους κύριους προβλεπτικούς αριθμούς αναφέρουμε επομένως και ένα 95% percentile bootstrap διάστημα εμπιστοσύνης σε 5,000 resamples του test set· για το κέρδος του multimodal χρησιμοποιούμε ένα *paired* bootstrap στο οποίο τα tabular και multimodal scores επανυπολογίζονται στο ίδιο resample, ώστε η κοινή διακύμανση του test-set να ακυρώνεται και το διάστημα να αντανakλά το ίδιο το κέρδος.

6 Αποτελέσματα & Συζήτηση

Παρουσιάζουμε αποτελέσματα φάση προς φάση και κλείνουμε με μια cross-phase σύνοψη και μια αφιερωμένη ανάλυση αξιοπιστίας (Ενότητα 6.14). Εκτός αν αναφέρεται διαφορετικά, κάθε πίνακας αποτελεσμάτων αναφέρει τον μέσο $\pm$ τυπική απόκλιση στα δέκα seeds του πρωτοκόλλου της Ενότητας 5.4· τα συνοδευτικά figures δείχνουν μια αντιπροσωπευτική μεμονωμένη εκτέλεση (seed 42). Όλοι οι ουσιαστικοί ισχυρισμοί υποστηρίζονται από τα *paired* τεστ σημαντικότητας στον Πίνακα 16.


6.1 Φάση 2 — Baseline supervised επίδοση

Ο Πίνακας 2 αναφέρει τα τρία baselines στο $\mathcal{D}_{te}$. Και τα τρία συγκεντρώνονται στενά γύρω από $\text{accuracy} \approx 0.87$ και $F1 \approx 0.78$, με $\text{AUC-ROC} \approx 0.92$. Το XGBoost προηγείται σε F1 και τα δέντρα σε accuracy, αλλά τα χάσματα είναι μικρά σε σχέση με τη διασπορά μεταξύ seeds ($\sigma_{F1} \approx 0.015$). Το MLP είναι ανταγωνιστικό παρά το μικρό του μέγεθος, κάτι που επικυρώνει την επαναχρησιμοποίησή του ως ελεγχόμενος κορμός στις επόμενες φάσεις. Αυτά τα νούμερα είναι συνεπή με τις αρχικές μελέτες σε αυτό το cohort (Martins et al., 2021; Realinho et al., 2022), όπου τα boosting ensembles ήταν επίσης τα ισχυρότερα μοντέλα· οι απόλυτοι αριθμοί δεν είναι άμεσα συγκρίσιμοι (εκείνες οι μελέτες χρησιμοποιούν την τρι-κλασική διατύπωση αντί της δυαδικής μας), αλλά η σειρά κατάταξης των μοντέλων και το συνολικό επίπεδο επίδοσης υποδεικνύουν ότι το pipeline είναι σωστά βαθμονομημένο και όχι αισιόδοξα tuned.

Σε όλη την εργασία ηγούμαστε με F1 και ROC-AUC. Ακολουθώντας τη σύμβαση αξιολόγησης EDM των Raftopoulos et al. (2025b), οι οποίοι υιοθετούν τον imbalance-robust συντελεστή συσχέτισης Matthews (MCC) ως κύρια μετρική για την εγκατάλειψη, η ρουτίνα μετρικών μας υπολογίζει επίσης MCC για κάθε μοντέλο, ώστε οι αναπαραγωγές να το αναφέρουν παράλληλα με F1/AUC· για αυτή τη δυαδική εργασία με $\sim 32\%$ θετικά, τα F1 και ROC-AUC ήδη χαρακτηρίζουν την επίδοση στη μειοψηφική κλάση, οπότε τα κρατάμε ως τα κύρια νούμερα.

Μοντέλο	Accuracy	F1	AUC-ROC
Random Forest	0.872 ± 0.008	0.780 ± 0.014	0.919 ± 0.012
XGBoost	0.870 ± 0.011	0.791 ± 0.017	0.918 ± 0.010
MLP (PyTorch)	0.854 ± 0.008	0.771 ± 0.013	0.901 ± 0.011

Πίνακας 2: Φάση 2 — Baseline supervised μοντέλα στο encoded διάνυσμα χαρακτηριστικών, μέσος $\pm$ std σε 10 seeds (Precision/Recall στο δημοσιευμένο JSON). Και τα τρία συγκεντρώνονται εντός μίας τυπικής απόκλισης μεταξύ seeds.



Σχήμα 3: Φάση 2 — Και οι τρεις baseline classifiers έχουν AUC-ROC αδιάκριτη σε δύο δεκαδικά, αλλά διαφωνούν αισθητά σε recall vs precision.


6.2 Φάση 3 — VAE oversampling

Προσθέτουμε $\approx 1,186$ synthetic minority δείγματα που παρήγαγε το εκπαιδευμένο hybrid VAE στις $\approx 3,318$ training γραμμές, δίνοντας ένα ισορροπημένο ($\approx 50/50$) augmented σύνολο. Ο Πίνακας 3 δείχνει ότι η μεταβολή σε σχέση με τη Φάση 2 είναι ουσιαστικά ουδέτερη: τα tree μοντέλα κινούνται κατά κλάσμα μιας μονάδας F1 και το MLP κατά λιγότερο από μία, όλα σαφώς εντός της διασποράς μεταξύ seeds. Αυτό συμφωνεί με την παρατήρηση EDA ότι η μειοψηφική κλάση είναι ήδη $\sim 32\%$ των δεδομένων, οπότε το synthetic oversampling φέρει περιορισμένη οριακή πληροφορία.


Μοντέλο (+VAE)	Acc	F1	AUC
Random Forest	0.872 ± 0.010	0.788 ± 0.017	0.919 ± 0.012
XGBoost	0.872 ± 0.010	0.789 ± 0.017	0.920 ± 0.011
MLP	0.849 ± 0.012	0.763 ± 0.016	0.899 ± 0.011

Πίνακας 3: Φάση 3 — VAE-augmented training set ($n_{tr} \approx 3,318 + 1,186 = 4,504$), μέσος $\pm$ std σε 10 seeds.

Η διανοητική συνεισφορά της Φάσης 3, ωστόσο, δεν είναι το προβλεπτικό κέρδος αλλά η μηχανική ανακάλυψη: ένα απελές *Gaussian VAE* σε *one-hot blocks* παράγει μη-έγκυρες *categorical* ανακατασκευές. Το hybrid likelihood μας + categorical sampling (Ενότητα 4.2.1) το επιλύει· το diffusion μοντέλο απαιτεί την ανάλογη πειθαρχία κατά τη δειγματοληψία (ένα *argmax snap*, Ενότητα 4.2.2).



Σχήμα 4: Φάση 3 — Μια επιτυχημένη εκπαίδευση VAE: η σύνθετη loss φθίνει μονότονα μόλις το KL warm-up ανασηκώσει τον encoder από το posterior collapse, και τα synthetic numerical marginals προσεγγίζουν τα πραγματικά.



Σχήμα 5: Φάση 3 — Baseline vs. VAE-augmented προβλεπτικές μετρικές για κάθε classifier. Το augmentation είναι περίπου metric-neutral, σε συμφωνία με τη μέτρια ($\sim 32\%$) ανισορροπία κλάσεων που συζητήθηκε παραπάνω.

6.3 Φάση 4 (Αναβάθμιση 1) — Diffusion vs. VAE

Το diffusion μοντέλο εκπαιδεύεται σταθερά σε τελικό ε -MSE ≈ 0.167 και παράγει $\approx 1,186$ synthetic minority δείγματα μέσω ancestral sampling. Η πιο διακριτή του επίδραση είναι στη διασπορά (spread) των synthetic numerical marginals (Πίνακας 4): στα δέκα seeds υποδιπλασιάζει την ασυμφωνία τυπικής απόκλισης του VAE ($0.271 \pm 0.017 \rightarrow 0.126 \pm 0.025$, paired Wilcoxon $p = 0.002$). Προσέχουμε να μην το διαβάσουμε ως καθαρό κέρδος πιστότητας. Το σφάλμα μέσου αυξάνεται κατά σχεδόν ταυτόσημο ποσό ($0.059 \rightarrow 0.207$, επίσης σημαντικό σε όλα τα δέκα seeds, $p = 0.002$), οπότε η αθροιστική ανά-χαρακτηριστικό απόκλιση ροπών $\Delta_\mu + \Delta_\sigma$ είναι ουσιαστικά αμετάβλητη (VAE 0.330 vs diffusion 0.333). Το diffusion μοντέλο επομένως αναδιανέμει το κατανομικό σφάλμα από τη διασπορά στον μέσο αντί να το μειώνει — συμπεριφορά συμβατή με το ότι κανένας oversampler δεν βελτιώνει το downstream F1, και γνωστή υπογραφή μιας υπο-εκπαιδευμένης reverse διαδικασίας. Στην categorical πλευρά, και οι δύο samplers αναπαράγουν στενά τις πραγματικές συχνότητες κατηγοριών (μέση ανά-block total variation 0.029 για το VAE και 0.071 για το argmax snap του diffusion· Πίνακας 4).

	Δ_μ	Δ_σ	TV _{cat}
VAE	0.059 ± 0.016	0.271 ± 0.017	0.029 ± 0.002
Diffusion	0.207 ± 0.039	0.126 ± 0.025	0.071 ± 0.006


Πίνακας 4: Φάση 4 — Κατανομική πιστότητα της synthetic μειοψηφίας, μέσος $\pm$ std σε 10 seeds (χαμηλότερο = καλύτερο παντού): μέση ανά-χαρακτηριστικό απόλυτη απόκλιση σε numerical μέσο (Δ_μ) και std (Δ_σ), συν τη μέση ανά-block total-variation απόσταση μεταξύ πραγματικών και synthetic categorical marginals (TV_{cat} — ο έλεγχος που πιάνει έναν χαλασμένο categorical sampler). Το diffusion μοντέλο υποδιπλασιάζει το Δ_σ αλλά διογκώνει το Δ_μ κατά συγκρίσιμο ποσό (και οι δύο κατευθύνσεις σημαντικές στο $p = 0.002$ στα δέκα seeds), οπότε το αθροιστικό numerical σφάλμα ροπών μένει ουσιαστικά αμετάβλητο (0.330 vs 0.333)· και οι δύο samplers εκπέμπουν ρεαλιστικά categorical marginals (TV ≤ 0.07).

Η επίδοση των downstream classifiers υπό diffusion augmentation (Πίνακας 5) είναι ισάξια με το VAE augmentation: στα seeds η διαφορά F1 diffusion-vs-VAE είναι εντός ± 0.005 για κάθε μο-

ντέλο και μη σημαντική για κανένα (RF -0.004 , $p = 0.105$ · XGB $+0.001$, $p = 0.789$ · MLP $+0.005$, $p = 0.232$). Το όφελος της diffusion παρέμβασης είναι επομένως μεθοδολογικό και στενό — μια synthetic μειοψηφία της οποίας η διασπορά ταιριάζει καλύτερα με τα πραγματικά δεδομένα (με αντίστοιχο κόστος στον μέσο της) — παρά μια αύξηση F1 σε αυτό το dataset.

Μοντέλο (+Diffusion)	Acc	F1	AUC
Random Forest	0.869 ± 0.011	0.784 ± 0.018	0.918 ± 0.013
XGBoost	0.873 ± 0.010	0.790 ± 0.017	0.920 ± 0.010
MLP	0.849 ± 0.014	0.768 ± 0.018	0.903 ± 0.011

Πίνακας 5: Φάση 4 — Diffusion-augmented training set, μέσος $\pm$ std σε 10 seeds.



(α') Diffusion ε -MSE training curve. (β') Real vs. diffusion-synth marginals. (γ') VAE vs. Diffusion side-by-side.


Σχήμα 6: Φάση 4 — Το diffusion μοντέλο παράγει πιο αιχμηρά numerical marginals από το VAE· η std-mismatch υποδιπλασιάζεται.

6.4 Φάση 3b — SMOTE: το κλασικό oversampling baseline

Ο Πίνακας 6 τοποθετεί το κλασικό SMOTE έναντι των δύο generative augmenters κάτω από τον πανομοιότυπο RF/XGBoost/MLP evaluator (Σχήμα 7). Το αποτέλεσμα είναι αποπληθωριστικό με τον πιο χρήσιμο τρόπο: το SMOTE ισοφαρίζει τις generative μεθόδους στο downstream F1 και μάλιστα τις ξεπερνά οριακά στο Random Forest (0.797 ± 0.013 έναντι του 0.788 του VAE, paired Wilcoxon $p = 0.014$)· για το XGBoost και το MLP το χάσμα SMOTE-VAE δεν είναι σημαντικό. Σε ένα dataset με 32% μειοψηφία, λοιπόν, κανένας oversampler — κλασικός ή generative — δεν αγοράζει ουσιαστικό προβλεπτικό κέρδος, που είναι ακριβώς ο λόγος που οι generative φάσεις επιχειρηματολογούνται στην *κατανομική πιστότητα* (Ενότητα 7.1) και όχι στο F1. Η συμπερίληψη του SMOTE baseline είναι αυτό που κάνει αυτό το επιχείρημα ειλικρινές.

Augmenter	RF F1	XGB F1	MLP F1
VAE (Phase 3)	0.788 ± 0.017	0.789 ± 0.017	0.763 ± 0.016
Diffusion (Phase 4)	0.784 ± 0.018	0.790 ± 0.017	0.768 ± 0.018
SMOTE (Phase 3b)	0.797 ± 0.013	0.790 ± 0.022	0.767 ± 0.021

Πίνακας 6: Φάση 3b — downstream F1 των τριών oversamplers, μέσος $\pm$ std σε 10 seeds. Το SMOTE είναι ανταγωνιστικό και με τις δύο generative μεθόδους· κανένας augmenter δεν κυριαρχεί.




Σχήμα 7: Φάση 3b — F1 και AUC των VAE, diffusion, και SMOTE augmentation (αντιπροσωπευτική εκτέλεση seed 42). Οι τρεις oversamplers είναι στατιστικά αδιάκριτοι στην downstream επίδοση.

6.5 Φάση 5 — Uncertainty sampling vs. random

Και οι δύο AL στρατηγικές ξεκινούν από το ίδιο seed 40 δειγμάτων και τρέχουν για 25 γύρους με $q = 20$, καταλήγοντας σε 540 labelled δείγματα (16.3% του training pool). Το uncertainty sampling νικά το random σε καθένα από τα δέκα seeds (Πίνακας 7, Σχήμα 8): το τελικό χάσμα F1 είναι +0.037 κατά μέσο όρο (0.795 ± 0.018 vs 0.758 ± 0.025 , paired Wilcoxon $p = 0.002$). Το uncertainty ισοφαρίζει το πλήρως-supervised baseline (F1 ≈ 0.79) με περίπου τον μισό προϋπολογισμό των 540 ετικετών, οπότε το heuristic ανακτά ένα ανταγωνιστικό μοντέλο με λιγότερο από 10% των ετικετών.

Στρατηγική	Final Acc	Final F1	Final AUC
Random	0.839 ± 0.017	0.758 ± 0.025	0.896 ± 0.017
Uncertainty (entropy)	0.869 ± 0.013	0.795 ± 0.018	0.916 ± 0.013

Πίνακας 7: Φάση 5 — Τελικές AL μετρικές στις 540 αποκτηθείσες ετικέτες, μέσος $\pm$ std σε 10 seeds. Το uncertainty νικά το random σε κάθε seed (paired Wilcoxon $p = 0.002$).



Σχήμα 8: Φάση 5 — Learning curves υπό uncertainty (μπλε) και random (γκρι) acquisition. Το προβάδισμα του uncertainty διευρύνεται μονότονα.


6.6 Φάση 6 (Αναβάθμιση 2) — RL-based active learning

Ο DQN agent εκπαιδεύεται για $E = 6$ episodes με το ε να φθίνει από ≈ 0.42 σε ένα κατώφλι 0.05. Κατά μέσο όρο στα δέκα seeds η greedy policy φτάνει F1 0.761 ± 0.020 (Πίνακας 8) — στατι-

στικά αδιάκριτη από το random acquisition (0.758 ± 0.025) και σημαντικά κάτω από το uncertainty sampling (0.795 , paired Wilcoxon $p = 0.002$). Στο μεμονωμένο split seed-42 η RL policy έτυχε να βρεθεί ανάμεσα στα δύο στο 0.795 , κάτι που ο μέσος μεταξύ seeds αποκαλύπτει ότι ήταν ευνοϊκή διακύμανση παρά πραγματικό προβάδισμα. Αυτό είναι ρεαλιστικό αποτέλεσμα — σύντομες εκτελέσεις DQN σε μικρό διακριτό action space και προϋπολογισμό δεν νικούν ένα καλά-tuned στατικό heuristic — και το αναφέρουμε ειλικρινά. Η άσκηση ωστόσο προσφέρει δύο παιδαγωγικά κέρδη. Πρώτον, η greedy policy τυπικά καταρρέει σε ένα μόνο stratum ανά seed — στην αντιπροσωπευτική εκτέλεση seed-42 είναι το stratum υψηλής απόστασης-από-το-centroid, αλλά στα δέκα seeds το επιλεγμένο stratum ποικίλλει (strata βασισμένα σε top-entropy, margin, ή απόσταση κυριαρχούν ανά seed) — οπότε το σταθερό εύρημα είναι η ίδια η κατάρρευση, όχι μια προτίμηση για κάποιο συγκεκριμένο σήμα acquisition: καμία μαθημένη πολιτική stratum δεν νικά εδώ την point-wise entropy. Δεύτερον, η συζήτηση reward-shaping (Ενότητα 4.3.2) αντιμετωπίζει άμεσα την ανησυχία reward-hacking που εγείρουν οι Lazaros et al. (2026): μια accuracy-based reward θα επέτρεπε, εκ κατασκευής, στον agent να διογκώσει το score του κάνοντας query εύκολα majority παραδείγματα, γι' αυτό η reward ορίζεται ως το ανά-γύρο κέρδος F_1 .

Strategy	Final Acc	Final F1	Final AUC
Random	0.839 ± 0.017	0.758 ± 0.025	0.896 ± 0.017
Uncertainty (heuristic)	0.869 ± 0.013	0.795 ± 0.018	0.916 ± 0.013
RL agent (greedy eval)	0.836 ± 0.019	0.761 ± 0.020	0.900 ± 0.012

Πίνακας 8: Φάση 6 — RL agent vs. heuristic baselines στις 540 ετικέτες, μέσος $\pm$ std σε 10 seeds. Η RL policy είναι αδιάκριτη από το random και κάτω από το uncertainty.



Σχήμα 9: Φάση 6 — Learning curves: η RL greedy policy βελτιώνεται μονότονα και ισοφαρίζει το random baseline μέχρι τον γύρο 25· με περισσότερα episodes και πλουσιότερη αναπαράσταση state, το χάσμα με το uncertainty θα έπρεπε να κλείσει περαιτέρω.

6.7 Self-labelled SSL baseline: Co-Forest και Self-Training

Τα δύο EDM anchor papers που είναι πλησιέστερα σε αυτό το project ακολουθούν τον άξονα self-labelling της αποδοτικότητας ετικετών παρά τον άξονα active-learning των Φάσεων 5–6. Για να βάλουμε αυτόν τον άξονα στο τραπέζι στα δικά μας δεδομένα — και να απαντήσουμε άμεσα πώς συμπεριφέρεται εδώ η χαρακτηριστική μέθοδος του επιβλέποντος — υλοποιήσαμε το **Co-Forest** (Li and Zhou, 2007), την ensemble self-labelled μέθοδο που οι Raftopoulos et al. (2025b) και Kostopoulos et al. (2025) βρίσκουν ισχυρότερη, από τον αρχικό αλγόριθμο (μια επιτροπή 7 δέντρων με confidence threshold 0.75, ταιριάζοντας τη διαμόρφωση του MOOC paper), και το τρέξαμε μαζί με το **Self-Training** του scikit-learn υπό το δικό τους πρωτόκολλο label-scarcity: αποκαλύπτουμε μόνο $r \in \{1, 2, 5, 10\}\%$ των training ετικετών (stratified), κρύβουμε τις υπόλοιπες ως unlabelled pool, και

αξιολογούμε στο ίδιο held-out test split που χρησιμοποιεί το υπόλοιπο pipeline (Πίνακας 9). Ακολουθώντας τους Raftopoulos et al. (2025b) αναφέρουμε το imbalance-robust MCC παράλληλα με το F1. Σημειώνουμε ότι το Self-Training τυλίγει το *ίδιο* balanced Random Forest με τη στήλη “Supervised (seed)”, οπότε η γραμμή του είναι το καθαρό *within-model* τεστ του αν βοηθά το unlabelled pool· το Co-Forest, πιστό στον ορισμό του, χρησιμοποιεί επιτροπή 7 δέντρων, οπότε ένα μικρό μέρος του χάσματός του προς το 300-δεντρικό supervised forest αντανακλά χωρητικότητα βάσης, όχι self-labelling — κάτι που καθιστά την υπεραπόδοσή του στο OULAD ακόμη πιο αξιοσημείωτη.

Προκύπτουν τρία ευρήματα, καθένα συνεπές με τα anchor papers και με τη διαρκή θέση αυτού του project:

1. **Σχεδόν-supervised ανάκτηση από λίγες ετικέτες.** Το Co-Forest ανακτά 74% του fully-supervised F1 (0.797) από 1% των ετικετών και 88% από 10% στο Realinho — και 91–99% στο OULAD (Πίνακας 10) — απηχώντας τη σχεδόν-supervised ανάκτηση που αναφέρουν οι Raftopoulos et al. (2025b) και Kostopoulos et al. (2025).
2. **Ensemble > απλό self-training.** Το Co-Forest νικά το απλό Self-Training σε κάθε ratio (π.χ. F1 0.646 έναντι 0.421 στο 2% στο Realinho· στο OULAD το Self-Training σχεδόν καταρρέει, F1 $\leq$ 0.10), αναπαράγοντας τη βασική κατάταξη και των δύο anchor papers, όπου οι ensemble/committee μέθοδοι κυριαρχούν του single-view self-training.
3. **Το αν βοηθά το unlabelled pool εξαρτάται από το cohort — μια αντιστροφή.** Στο Realinho το pool δεν νικά ένα class-balanced supervised RF στο ίδιο labelled seed (το Co-Forest το ισοφαρίζει στο 1%, 0.588 έναντι 0.585, και έπειτα υπολείπεται ελαφρώς) — το self-labelling ανάλογο του generative-oversampler tie μας (Ενότητα 7.1). Στο OULAD, όπου το demographics-only σήμα είναι ασθενές και ένα seed-trained μοντέλο φτωχό, το Co-Forest νικά το supervised seed σε κάθε ratio και ανακτά 91–99% του (tree-based) fully-supervised F1 από μόλις 1–10% ετικετών (Πίνακας 10, Σχήμα 10). Το unlabelled pool βοηθά ακριβώς εκεί όπου το supervised σήμα είναι ασθενέστερο — μια εξαρτώμενη-από-το-cohort αντιστροφή που αντικατοπτρίζει την active-learning αντιστροφή των Φάσεων 5–6 μεταξύ των ίδιων δύο datasets και το συμπέρασμα “καμία μεμονωμένη μέθοδος δεν κυριαρχεί” των Raftopoulos et al. (2025a).


Για αναφορά, ο active learner μας φτάνει το fully-supervised F1 στο 540-ετικετών ($\sim 16\%$) προϋπολογισμό του επιλέγοντας ποια σημεία να επισημάνει (Πίνακας 8)· οι δύο άξονες label-efficiency είναι συμπληρωματικοί, και σε αυτό το cohort ο active άξονας — που επιλέγει πληροφοριακά σημεία — υπερτερεί ελαφρώς του παθητικού self-labelling.

Ετικέτες	Supervised (seed)	Self-labelled SSL	
	RF (balanced) F1 / MCC	Self-Training F1 / MCC	Co-Forest F1 / MCC
1%	0.585 / 0.497	0.293 / 0.292	0.588 / 0.413
2%	0.657 / 0.572	0.421 / 0.397	0.646 / 0.498
5%	0.740 / 0.655	0.690 / 0.616	0.693 / 0.562
10%	0.754 / 0.674	0.714 / 0.643	0.705 / 0.578

Πίνακας 9: Self-labelled SSL στο Realinho υπό label scarcity: test-set F1 / MCC, μέσος σε 10 label-mask seeds. Fully-supervised άνω φράγμα (όλες οι training ετικέτες): F1 0.797, MCC 0.723. Το Co-Forest είναι πιστή επανυλοποίηση των Li and Zhou (2007)· το Self-Training είναι του scikit-learn, και τα δύο με balanced-RF / balanced-tree βάση. Το ensemble Co-Forest κυριαρχεί του απλού Self-Training, αλλά κανένα δεν νικά το class-balanced supervised μοντέλο στο ίδιο labelled seed.

Ετικέτες	Supervised (seed)	Self-labelled SSL	
	RF (balanced) F1 / MCC	Self-Training F1 / MCC	Co-Forest F1 / MCC
1%	0.214 / 0.072	0.052 / 0.034	0.319 / 0.077
2%	0.243 / 0.111	0.047 / 0.040	0.316 / 0.097
5%	0.279 / 0.135	0.078 / 0.067	0.332 / 0.111
10%	0.296 / 0.146	0.099 / 0.063	0.344 / 0.121

Πίνακας 10: Self-labelled SSL στο *OULAD* υπό label scarcity: test-set F1 / MCC, μέσος σε 5 label-mask seeds. Tree-based fully-supervised άνω φράγμα: F1 0.346, MCC 0.125 (το demographics-only σήμα του *OULAD* είναι ασθενές για όλα τα tree μοντέλα· βλ. Φάση 2). Η αντιστροφή: το Co-Forest (έντονα) νικά το supervised seed σε κάθε ratio και ανακτά 91–99% του fully-supervised F1 από 1–10% ετικετών — το αντίθετο του Realinho.



Σχήμα 10: Self-labelled SSL υπό label scarcity — test F1 ως προς το labelled ratio: supervised seed (γκρι), Self-Training (μπλε), Co-Forest (πράσινο), με το fully-supervised άνω φράγμα (διακεκομμένη). *Αριστερά:* Realinho — το Co-Forest ακολουθεί και ισοφαρίζει το supervised seed. *Δεξιά:* OULAD — το Co-Forest βρίσκεται πάνω από το supervised seed σε κάθε ratio, η αντιστροφή ανά cohort που συζητείται στο κείμενο.

6.8 Φάση 7 — Post-hoc έλεγχος fairness

Επανεκπαιδεύουμε και τους τρεις classifiers υπό τις τρεις στρατηγικές augmentation (baseline, VAE, diffusion) και ελέγχουμε τις τυπικές group αποκλίσεις (Πίνακας 11). Αναδύονται δύο σταθερά μοτίβα:


1. Σε όλα τα εννέα (μοντέλο, augmentation) κελιά το demographic-parity χάσμα συγκεντρώνεται στενά γύρω στο $\Delta_{DP} \approx 0.20$ με επικαλυπτόμενα διαστήματα μεταξύ seeds — *το augmentation από μόνο του δεν διορθώνει την αδικία*· απλώς μεταφέρει το εγγενές base-rate χάσμα σε ένα μεγαλύτερο training set.
2. Κανένας augmenter δεν μειώνει συστηματικά καμία από τις δύο αποκλίσεις: κάθε κελί βρίσκεται εντός μίας τυπικής απόκλισης μεταξύ seeds από το baseline, τόσο για το Δ_{DP} όσο και για το Δ_{EqOdds} — διακυμάνσεις μεμονωμένων κελιών σε ένα seed δεν πρέπει να διαβάζονται ως φαινόμενα του augmentation.

Αυτή είναι ακριβώς η εξάρτηση-από-το-καθεστώς που αναφέρουν οι [Kostopoulos et al. \(2025\)](#): το synthetic augmentation τους βελτίωσε το fairness μόνο στο *low-label* καθεστώς, όπου οι synthetic γραμμές αντισταθμίζουν το bias του αραιού συνόλου, και προειδοποιούν ρητά ότι “η επάρκεια ετικετών από μόνη της δεν εγγυάται fairness.” Το δικό μας cohort είναι πλήρως labelled, οπότε η αδικία

ζει στα base rates παρά στη σπανιότητα ετικετών, και το oversampling — που διατηρεί αυτά τα base rates — δεν μπορεί να τη μετακινήσει. Κάθε άλλο παρά αντιφάσκει με το αποτέλεσμα τους, η Φάση 7 μας είναι το full-label πόρισμά του. Αυτές οι παρατηρήσεις υποκινούν εμπειρικά την in-processing παρέμβαση της Φάσης 8.

Aug.	Μοντέλο	Δ_{DP}	Δ_{EqOdds}
Baseline	RF	0.199 ± 0.029	0.091 ± 0.020
	XGBoost	0.216 ± 0.032	0.109 ± 0.021
	MLP	0.211 ± 0.035	0.100 ± 0.033
VAE	RF	0.210 ± 0.025	0.094 ± 0.019
	XGBoost	0.208 ± 0.032	0.098 ± 0.015
	MLP	0.215 ± 0.023	0.109 ± 0.024
Diffusion	RF	0.212 ± 0.029	0.099 ± 0.020
	XGBoost	0.207 ± 0.032	0.097 ± 0.017
	MLP	0.216 ± 0.032	0.109 ± 0.032

Πίνακας 11: Φάση 7 — Post-hoc fairness αποκλίσεις στο test set, μέσος $\pm$ std σε 10 seeds. Και τα εννέα κελιά συγκεντρώνονται κοντά στο $\Delta_{DP} \approx 0.20$ · το augmentation δεν το φέρνει κάτω από το base-rate χάσμα.



Σχήμα 11: Φάση 7 — Fairness-disparity bars ανά augmentation και παραλλαγή μοντέλου. Το MLP είναι ο μόνος learner του οποίου η απόκλιση αλλάζει ουσιαστικά με το augmentation· οι tree-based learners παραμένουν κοντά στο 0.20 ανεξαρτήτως.

6.9 Φάση 8 (Αναβάθμιση 3) — In-processing fairness penalty


Εκπαιδεύουμε επτά MLPs μεταβάλλοντας $\lambda \in \{0, 0.1, 0.5, 1, 2, 5, 10\}$. Ο Πίνακας 12 αναφέρει την τροχιά accuracy/fairness μεταξύ seeds· το Σχήμα 12 δείχνει το trade-off ενός seed και το Σχήμα 13 το multi-seed μέσο frontier. Τα σταθερά ευρήματα είναι:

- **Η ποινή λειτουργεί.** Η ενεργοποίησή της μειώνει σταθερά το demographic-parity χάσμα: στο $\lambda = 1$, το Δ_{DP} πέφτει από 0.211 ± 0.035 σε 0.083 ± 0.039 — μείωση $\sim 60\%$ που ισχύει σε όλα τα δέκα seeds (paired Wilcoxon $p = 0.002$).
- **Το fairness δεν είναι δωρεάν.** Αυτή η μείωση κοστίζει ~ 1.6 μονάδες accuracy κατά μέσο όρο ($0.854 \rightarrow 0.838$) — περισσότερο απ' ό,τι υποδείκνυε το μεμονωμένο σταθερό split (όπου το κόστος φαινόταν κάτω από μία μονάδα). Το trade-off accuracy/fairness είναι πραγματικό, όχι δωρεάν γεύμα.
- **Το σημείο λειτουργίας είναι μια περιοχή, όχι μια κόψη μαχαιριού.** Η ακριβής διασταύρωση είναι ευαίσθητη στο seed ($\sigma_{\Delta_{DP}} \approx 0.04$ στο $\lambda = 1$): στον μέσο μεταξύ seeds είναι το $\lambda \approx 2-5$ που


βρίσκεται στο frontier (το $\lambda = 2$ φτάνει τη χαμηλότερη απόκλιση, 0.046 ± 0.028), και το $\lambda = 1$ είναι στην πραγματικότητα αυστηρά *dominated* από το $\lambda = 5$ (καλύτερο και στους δύο άξονες στον μέσο). Ένας practitioner θα έπρεπε να επιλέξει το λ από αυτή τη ζώνη έναντι ενός στόχου ανώτατου ορίου απόκλισης, παρά να διαβάσει μία μόνο “βέλτιστη” τιμή από ένα split.

λ	Acc	F1	Δ_{DP}
0.0	0.854 ± 0.008	0.771 ± 0.013	0.211 ± 0.035
0.1	0.851 ± 0.007	0.765 ± 0.013	0.197 ± 0.031
0.5	0.852 ± 0.008	0.766 ± 0.011	0.154 ± 0.038
1.0	0.838 ± 0.010	0.747 ± 0.013	0.083 ± 0.039
2.0	0.828 ± 0.013	0.741 ± 0.017	0.046 ± 0.028
5.0	0.844 ± 0.013	0.757 ± 0.017	0.051 ± 0.032
10.0	0.847 ± 0.021	0.757 ± 0.024	0.062 ± 0.038

Πίνακας 12: Φάση 8 — In-processing fairness λ -sweep, μέσος $\pm$ std σε 10 seeds. Η ποιινή μειώνει σταθερά το Δ_{DP} · το $\lambda \approx 2-5$ βρίσκεται στο μέσο Pareto frontier, με το $\lambda = 1$ αυστηρά *dominated* από το $\lambda = 5$.




(α') Pareto frontier accuracy vs. Δ_{DP} .



(β') Τροχιές μετρικών vs. λ .

Σχήμα 12: Φάση 8 — Εμπειρικό trade-off accuracy/ Δ_{DP} από το λ -sweep (αντιπροσωπευτική εκτέλεση seed 42).




Σχήμα 13: Φάση 8 — Pareto frontier accuracy/ Δ_{DP} , μέσος $\pm$ std στα δέκα seeds. Τα error bars επιβεβαιώνουν ότι το ακριβές σημείο λειτουργίας είναι ευαίσθητο στο seed και ότι το $\lambda \approx 2-5$ (όχι το $\lambda = 1$) ιχνηλατεί το μέσο frontier.

6.10 Φάση 9 (Αναβάθμιση 4) — Multimodal DistilBERT επέκταση

Υπολογίζουμε frozen DistilBERT embeddings για όλα τα $\approx 4,424$ (simulated) σχόλια φοιτητών, τα μειώνουμε σε 32 PCs (PCA προσαρμοσμένο μόνο στα training embeddings), τα κανονικοποιούμε, και τα συνενώνουμε με το tabular διάνυσμα ώστε να σχηματίσουμε το multimodal χαρακτηριστικό. Η επανεκπαίδευση των τριών classifiers παράγει την ισχυρότερη διαμόρφωση της μελέτης (Πίνακας 13): το F1 ανεβαίνει κατά +0.060 έως +0.066 και το AUC κατά $\approx +0.04$ σε σχέση με τα tabular-only baselines, και το κέρδος είναι σημαντικό σε κάθε seed (paired Wilcoxon $p = 0.002$ και για τα τρία μοντέλα). Ένα paired bootstrap στο test set του seed-42 συμφωνεί — το κέρδος F1 του RF είναι +0.072 με 95% διάστημα $[+0.041, +0.103]$, αποκλείοντας το μηδέν (Πίνακας 16).

Μοντέλο	Acc	F1	AUC
Random Forest (tab. only)	0.872 ± 0.008	0.780 ± 0.014	0.919 ± 0.012
Random Forest (+ DistilBERT)	0.902 ± 0.009	0.840 ± 0.016	0.956 ± 0.006
XGBoost (tab. only)	0.870 ± 0.011	0.791 ± 0.017	0.918 ± 0.010
XGBoost (+ DistilBERT)	0.905 ± 0.005	0.852 ± 0.009	0.961 ± 0.005
MLP (tab. only)	0.854 ± 0.008	0.771 ± 0.013	0.901 ± 0.011
MLP (+ DistilBERT)	0.895 ± 0.007	0.837 ± 0.012	0.955 ± 0.005

Πίνακας 13: Φάση 9 — Multimodal (tabular + DistilBERT) vs tabular-only classifiers, μέσος $\pm$ std σε 10 seeds. Η text modality ανεβάζει το F1 κατά ~ 0.06 σε κάθε μοντέλο (όλα $p = 0.002$).



(α') Επίδοση tabular-only vs. multimodal.

(β') 2-D PCA των DistilBERT pooled embeddings.

Σχήμα 14: Φάση 9 — Τα DistilBERT embeddings ομαδοποιούνται κατά sentiment, και ο multimodal classifier εκμεταλλεύεται αυτό το σήμα καθαρά.

Επιφύλαξη. Η βελτίωση που αναφέρθηκε παραπάνω στηρίζεται σε *simulated* σχόλια των οποίων ο τόνος συσχετίζεται με το αποτέλεσμα. Το pipeline είναι μεθοδολογικά σωστό (frozen encoder, leakage-safe PCA), αλλά οι απόλυτοι αριθμοί αυτής της φάσης πρέπει να διαβάζονται ως εκτιμήσεις οροφής του τι θα μπορούσε να επιτύχει μια multimodal επέκταση μόλις υπάρξει ένα γνήσιο κανάλι ελεύθερου κειμένου σε παραγωγή. Κλείνουμε αυτό το χάσμα όσο επιτρέπουν τα δημόσια δεδομένα στην επικύρωση πραγματικού κειμένου παρακάτω.

Πόσο σήμα εισάγει το simulated κείμενο; Επειδή κάθε σχόλιο της Φάσης 9 είναι ντετερμινιστική κλήρωση από τρεις tone pools των οποίων η μίξη εξαρτάται από το αποτέλεσμα, η πληροφορία που φέρει το κανάλι κειμένου για το label υπολογίζεται σε κλειστή μορφή: $I(\text{text}; y) \approx I(\text{pool}; y) = 0.278$ bits (εμπειρικός έλεγχος 0.285), δηλ. $\sim 31\%$ της εντροπίας label $H(y) = 0.906$ bits· ένας classifier με μόνο το κείμενο φτάνει dropout F1 = 0.70 (CODE/analysis/simulated_text_mi.py). Το ~ 0.06 multimodal F1 κέρδος είναι επομένως μια οροφή κατασκευής που γνωστοποιούμε και ποσοτικοποιούμε, όχι train/test leakage — ο encoder είναι frozen και τα PCA/scaler προσαρμόζονται μόνο στο train, οπότε είναι μια ιδιότητα construct-validity του synthetic, label-correlated κειμένου. Όπως δείχνει η Ενότητα 6.12, αυτό καθιστά τη δική μας μεταχείριση του multimodal κειμένου πιο ειλικρινή από τις σύγχρονες εναλλακτικές, όχι λιγότερο.

6.11 Φάση 9b — επικύρωση του fusion protocol σε πραγματικό κείμενο


Το κέρδος της Φάσης-9 στηρίζεται σε simulated κείμενο, οπότε οριοθετεί μόνο το τι θα μπορούσε να αποδώσει το protocol. Για να ελέγξουμε ότι ο ίδιος ο μηχανισμός λειτουργεί σε γνήσιο φοιτητικό γραπτό, εφαρμόζουμε το πανομοιότυπο frozen-DistilBERT + train-only-PCA pipeline σε ένα πραγματικό σώμα εκπαιδευτικού κειμένου: posts από discussion-forum χειροκίνητα κωδικοποιημένα για urgency (Švábenský et al., 2023), εκπαιδευοντας στο coded multi-course σύνολο (3,503 posts, 19% urgent) και ελέγχοντας cross-domain σε ένα held-out δείγμα των Stanford MOOC Posts (Agrawal and Paepcke, 2014) (6,000 posts, 22% urgent· urgent = rating ≥ 4 στην κλίμακα 1–7). Η εργασία είναι ανίχνευση urgency, όχι dropout — κανένα δημόσιο dataset δεν ζευγαρώνει dropout αποτελέσματα με ελεύθερο κείμενο — οπότε αυτό επικυρώνει το protocol κωδικοποίησης, όχι το dropout-multimodal αποτέλεσμα.

Το protocol μεταφέρεται καθαρά σε πραγματικό κείμενο. Τα posts κωδικοποιούνται με τον αμετάβλητο encoder της Φάσης-9, συμπεριλαμβανομένου του παραθύρου truncation 48 tokens (δηλ. η ταξινόμηση δουλεύει από τις πρώτες ~ 35 λέξεις κάθε post — όριο διαστασιολογημένο για τα σύντομα simulated σχόλια, που το γνωστοποιούμε εδώ επειδή τα πραγματικά forum posts είναι

μακρύτερα· αν μη τι άλλο υποεκτιμά το διαθέσιμο σήμα). Με frozen embeddings μειωμένα σε 32 train-only principal components, και οι δύο classifiers φτάνουν $AUC \approx 0.82$ στο cross-domain test set (logistic regression: $AUC 0.825$, $F1 0.555$ σε υψηλό recall· random forest: $AUC 0.824$, $F1 0.325$ σε υψηλό precision· Πίνακας 14, Σχήμα 15). Η leakage-safe κωδικοποίηση δεν είναι επομένως artefact του simulated κειμένου — παράγει discriminative χαρακτηριστικά από αυθεντικό φοιτητικό γραπτό ακόμη και υπό domain shift.


Μοντέλο	Accuracy	Precision	Recall	F1 / AUC
Logistic regression	0.716	0.421	0.812	0.555 / 0.825
Random forest	0.813	0.763	0.207	0.325 / 0.824

Πίνακας 14: Φάση 9b — ανίχνευση urgency σε πραγματικό forum κείμενο (frozen DistilBERT + train-only PCA), εκπαιδευμένο στα coded courses και ελεγμένο cross-domain στα Stanford MOOC Posts.



Σχήμα 15: Φάση 9b — το leakage-safe DistilBERT protocol σε γνήσιο εκπαιδευτικό κείμενο φτάνει $AUC \approx 0.82$ για ανίχνευση urgency υπό domain shift train→test.

Εύρος: έξι πραγματικοί constructs, όχι ένας. Το corpus του Stanford φέρει έξι human-annotated constructs πέρα από το μοναδικό urgency proxy παραπάνω. Τρέχοντας το ίδιο leakage-safe protocol σε όλους (CODE/analysis/stanford_multilabel_protocol.py· $n=29,604$ posts, best-of-two test AUC ανά construct) προβλέπει καθέναν σαφώς πάνω από την τύχη — Question 0.90, Urgency 0.89, Opinion 0.88, Sentiment 0.85, Confusion/Answer 0.84 (μέσος ≈ 0.86 · και τα δώδεκα LogReg/RF AUCs βρίσκονται στο $[0.81, 0.90]$, Σχήμα 16). Αυτό γενικεύει την επικύρωση πραγματικού κειμένου από μία proxy εργασία σε έξι, επιβεβαιώνοντας ότι το encoding pipeline είναι ορθό σε γνήσιο φοιτητικό γραπτό σε όλους τους constructs, όχι μόνο στο urgency.



Σχήμα 16: Φάση 9b (εύρος) — το leakage-safe DistilBERT protocol στα πραγματικά Stanford MOOC Posts, test AUC ανά construct (LogReg vs. RandomForest)· και οι έξι constructs προβλέπονται σαφώς πάνω από την τύχη.

Υπάρχει διαθέσιμο corpus με πραγματικό κείμενο + dropout; Μια συστηματική αναζήτηση (DATASETS/candidate_text_datasets.md) δεν βρήκε κανένα μεγάλο, ανοιχτό, αγγλικό dataset που ζευγαρώνει φοιτητικό ελεύθερο κείμενο με label dropout — το κενό είναι δομικό (privacy/IP). Οι ρεαλιστικές επιλογές είναι το *MOOCubeX* (Yu et al., 2021) (κατεβάσιμα πραγματικά σχόλια με παραγωγίσιμο dropout, αλλά κινεζικά, χρειάζεται multilingual encoder)· το *MORF* enclave (Gardner et al., 2018) (πραγματικό αγγλικό MOOC forum κείμενο + completion, αλλά privacy enclave που απαιτεί θεσμικό Data-Use Agreement)· και το cohort *Tecnológico de Monterrey* (Alvarado-Uribe et al., 2022) (μεγάλο, access-gated, *tabular-only* σύνολο — υποψήφιο τρίτο cohort για generalisation/fairness, όχι για κείμενο). Έχουμε φτιάξει το scaffold του MORF submission (CODE/analysis/morf/: plan, access checklist, και leakage-safe extract/train/test κώδικα που αντικατοπτρίζει αυτό το protocol) έτοιμο να τρέξει μόλις υπάρξει DUA· είναι η μία αγγλική διαδρομή από μια επίδειξη protocol σε ένα γνήσιο multimodal-dropout αποτέλεσμα.

6.12 Επανεκτίμηση σύγχρονων ισχυρισμών “multimodal-dropout”


Δύο papers του 2025 φαίνεται να προλαβαίνουν μια multimodal-dropout συνεισφορά· σε επισκόπηση, κανένα δεν περνά τον πήχη πραγματικού κειμένου που υπονοεί.

- **TRIAD-Drop** (Mihoubi et al., 2025) (abstract: 89% accuracy, F1 0.88· το 0.85 στο README του repo τους είναι three-class macro-F1) δημοσιεύει ένα MIT repo του οποίου το dataset είναι η ίδια βάση *UCI Realinho* που χρησιμοποιούμε, εμπλουτισμένη με μια στήλη *student_comment* παραγόμενη από **GPT-4.5**. Τρέχοντας το leakage-safe text-only protocol μας στα δικά τους σχόλια (CODE/analysis/triad_synthetic_text_mi.py) προβλέπει το dropout από το κείμενο μόνο σε AUC 0.99 / F1 0.94· ένας text-only classifier που ξεπερνά ακόμη και το επιτευχθέν tabular AUC (~0.92) σημαίνει ότι τα σχόλια φέρουν πληροφορία label πέρα από όσα εξάγουν τα tabular μοντέλα μας. Το leak είναι μάλιστα λεξιλογικό: **89.9% των σχολίων Graduate-row περιέχουν κυριολεκτικά “graduat”** (έναντι 0.7% των Dropout rows), και ένας κανόνας τριών γραμμών keyword φτάνει μόνος του 77% three-class accuracy. Το synthetic κείμενό τους επομένως σχεδόν καθορίζει το label, αδημοσίευτο και μη ποσοτικοποιημένο. (Συγκρίνουμε *protocols* στο released artifact τους, όχι test-set scores — το 0.88 τους είναι στο δικό τους split — και δεν κάνουμε ισχυρισμό για πρόθεση.)
- **SentiDrop** (Zerkouk et al., 2025) χρησιμοποιεί ένα πραγματικό αλλά ιδιωτικό cohort (πλατφόρμα distance-learning του Université TÉLUQ) και δεν δείχνει κανένα κατεβάσιμο dataset.

Έτσι τα σύγχρονα multimodal-dropout αποτελέσματα σε ανοιχτά δεδομένα στηρίζονται σε *synthetic* κείμενο, και τα πραγματικού-κειμένου σε *απρόσιτα* δεδομένα. Το σκόπιμα ηπιότερο (0.28 bits), γνωστοποιημένο και ποσοτικοποιημένο *synthetic* κείμενό μας (Ενότητα 6.11) μαζί με μια επικύρωση protocol πραγματικού κειμένου έξι constructs δείχνει να είναι η πιο αυστηρή μεταχείριση.

6.13 Cross-phase σύνθεση

Το Σχήμα 17 συγκεντρώνει το F1 στις πιο σημαντικές διαμορφώσεις και επιθέτει το Pareto frontier της Φάσης 8.



Σχήμα 17: Cross-phase πρόοδος F1 (αριστερά) και το Pareto frontier accuracy / Δ_{DP} από τη Φάση 8 (δεξιά).

Ο Πίνακας 15 συνοψίζει την ισχυρότερη διαμόρφωση σε κάθε μεθοδολογικό άξονα.

Άξονας	Βέλτιστη διαμόρφωση	Acc	F1	AUC	Fairness
Προβλεπτικό (μόνο tabular)	XGBoost (P2)	0.870	0.791	0.918	0.216 (DP)
Προβλεπτικό (multimodal)	XGB + DistilBERT (P9)	0.905	0.852	0.961	—
Διασπορά (σ)	Diffusion (P4)	—	—	—	$\Delta_\sigma = 0.126$
Αποδοτικότητα ετικετών	Uncertainty AL (P5)	0.869	0.795	0.916	—
Fairness	Fair-MLP $\lambda = 2$ (P8)	0.828	0.741	—	0.046 (DP)

Πίνακας 15: Master σύνθεση — βέλτιστη διαμόρφωση κατά μήκος κάθε μεθοδολογικού άξονα (μέσος σε 10 seeds). Η ισχυρότερη συνολικά προβλεπτική διάταξη είναι το multimodal XGBoost· η δικαιότερη είναι το in-processing MLP στο $\lambda \approx 2$.

Ο άξονας αποδοτικότητας ετικετών στον πίνακα είναι το active-learning βέλτιστο (uncertainty AL)· ο self-labelling αντίστοιχός του, το Co-Forest, ανακτά συγκρίσιμο μερίδιο του supervised F1 από 1–10% των ετικετών και ξεπερνά ένα supervised seed μόνο στο OULAD (Ενότητα 6.7, Σχήμα 10) — οπότε και οι δύο δρόμοι αποδοτικότητας ετικετών μένουν λίγο κάτω, όχι πάνω, από ένα καλά εκπαιδευμένο supervised μοντέλο στο cohort μέτριας ανισοροπίας Realinho.


6.14 Αξιοπιστία μεταξύ seeds

Ο Πίνακας 16 συγκεντρώνει τα paired τεστ σημαντικότητας πίσω από κάθε συγκριτικό ισχυρισμό αυτής της ενότητας, και το Σχήμα 18 δείχνει τα κύρια νούμερα F1 με τα error bars τους μεταξύ seeds. Πέντε φαινόμενα επιβιώνουν της μεταβολής seed-και-split στο $p = 0.002$ (το κατώφλι για ένα δίπλευρο Wilcoxon test σε $n = 10$): το multimodal κέρδος και στα τρία μοντέλα· η υπεροχή του uncertainty έναντι του random acquisition· η *κατωτερότητα* του RL agent έναντι του uncertainty· η μείωση του Δ_{DP} από την in-processing ποινή· και ο υποδιπλασιασμός του χάσματος

διασποράς-κατανομής από το diffusion μοντέλο. Δύο οικογένειες ισχυρισμών, αντιθέτως, δεν είναι σταθερές, και δεν τους κάνουμε πλέον: ούτε το diffusion ούτε το SMOTE παράγει ουσιαστικό πλεονέκτημα downstream-F1 έναντι του VAE (διαφορές εντός ± 0.01 · καμία σύγκριση diffusion-vs-VAE δεν φτάνει $p < 0.05$, και η μόνη υπο-0.05 σύγκριση SMOTE, $p = 0.014$ για RF, δεν επιβιώνει της διόρθωσης), και το ακριβές σημείο λειτουργίας της Φάσης-8 μεταβάλλεται αρκετά μεταξύ seeds ώστε πρέπει να αναφέρεται ως περιοχή παρά ως σημείο (Ενότητα 7.3). Τέλος, επειδή αυτές οι συγκρίσεις τρέχουν ταυτόχρονα, επαληθεύσαμε ότι το σύνολο των κύριων ευρημάτων επιβιώνει και του familywise-error control: εφαρμόζοντας Holm–Bonferroni και απλό Bonferroni εντός της οικογένειας κάθε dataset ($m=13$ τεστ), κάθε κύριο εύρημα διατηρεί προσαρμοσμένο $p = 13 \times 0.00195 = 0.025 < 0.05$, ενώ οι μη-διεκδικούμενες συγκρίσεις oversampler (καλύτερο raw $p = 0.014$, SMOTE-vs-VAE F1 για RF) δεν επιβιώνουν — οπότε οι πολλαπλές συγκρίσεις ενισχύουν το σύνολο των κύριων ευρημάτων αντί να το απειλούν.

Σύγκριση (10 seeds)	mean A	mean B	Δ	p
Multimodal > tabular F1 (RF)	0.840	0.780	+0.060	0.002
Multimodal > tabular F1 (XGB)	0.852	0.791	+0.060	0.002
Multimodal > tabular F1 (MLP)	0.837	0.771	+0.066	0.002
Uncertainty > random AL F1	0.795	0.758	+0.037	0.002
RL vs. uncertainty AL F1	0.761	0.795	−0.034	0.002
Fair-MLP $\lambda=1 < \lambda=0$ DP	0.083	0.211	−0.128	0.002
Diffusion < VAE std-mismatch	0.126	0.271	−0.145	0.002
Diffusion vs. VAE F1 (RF)	0.784	0.788	−0.004	0.105
Diffusion vs. VAE F1 (XGB)	0.790	0.789	+0.001	0.789
Diffusion vs. VAE F1 (MLP)	0.768	0.763	+0.005	0.232
SMOTE vs. VAE F1 (RF)	0.797	0.788	+0.009	0.014
SMOTE vs. VAE F1 (XGB)	0.790	0.789	+0.001	0.846
SMOTE vs. VAE F1 (MLP)	0.767	0.763	+0.004	0.432

Πίνακας 16: Paired δίπλευρα Wilcoxon signed-rank τεστ στα δέκα seeds (τα “mean A / mean B” είναι οι μέσοι μεταξύ seeds των δύο πλευρών· το Δ είναι η διαφορά τους). Το έντονο p σημαίνει σημαντικότητα στο $\alpha = 0.05$ · το $p = 0.002$ είναι το κατώφλι του τεστ για $n = 10$. Το άνω μπλοκ απαριθμεί τα σταθερά φαινόμενα, το κάτω μπλοκ τις συγκρίσεις augmentation που δεν είναι σημαντικές.



Σχήμα 18: Κύριο test-F1 σε όλο το pipeline, μέσος $\pm$ std σε δέκα seeds. Οι multimodal διαμορφώσεις στέκονται ξεκάθαρα πάνω από τα tabular baselines και τους τρεις oversamplers, που είναι αμοιβαία αδιάκριτοι.

6.15 Γενίκευση σε ένα δεύτερο dataset (OULAD)


Ισχύουν αυτά τα ευρήματα πέρα από ένα cohort; Ξανατρέξαμε ολόκληρο το pipeline (prep + φάσεις 2–8 + SMOTE, δέκα seeds, πανομοιότυπο protocol) στο Open University Learning Analytics Dataset (Kuzilek et al., 2017): 32,593 εγγραφές με αποτέλεσμα *Withdrawn* (31.2% — κοντά στο 32.1% του Realinho) και το ίδιο δυαδικό προστατευόμενο χαρακτηριστικό *gender*. Χρησιμοποιούμε σκόπιμα μόνο τις δημογραφικές στήλες και study-load του studentInfo (οι πίνακες registration κωδικοποιούν την ημερομηνία un-registration, που θα διέρρηε την ετικέτα), οπότε αυτό είναι ένα δύσκολο, behaviour-free setting έγκαιρης πρόβλεψης: η withdrawal είναι μόνο ασθενώς προβλέψιμη από δημογραφικά (baseline AUC ≈ 0.6 –0.68, XGBoost F1 0.495 ± 0.007), ένα σκόπιμα αυστηρότερο τεστ από το Realinho.

Δύο από τα model-agnostic συμπεράσματα αναπαράγονται ή οξύνονται· τα δύο behaviour-sensitive όχι, που είναι το ίδιο το χρήσιμο αποτέλεσμα:

- **To oversampling εξακολουθεί να μη βοηθά — και εδώ βλάπτει** (Πίνακας 17). Κανένας augmenter δεν νικά το baseline συνολικά· το VAE *κόβει* το XGBoost F1 από 0.495 σε 0.323 ($p = 0.002$) και το SMOTE βοηθά μόνο το Random Forest (+0.041, $p = 0.002$). Το μάθημα του Realinho αναπαράγεται και, σε αυτόν τον σχεδόν-δυαδικό feature space, ενισχύεται.
- **To diffusion εξακολουθεί να ταιριάζει καλύτερα τη διασπορά**: υποδιπλασιάζει περίπου την numerical std-mismatch του VAE ($0.224 \rightarrow 0.099$, $p = 0.014$), όπως στο Realinho (αναφέρουμε μόνο το Δ_σ στο OULAD· όπως στο Realinho, ένα κέρδος διασποράς δεν συνεπάγεται αναγκαστικά καθαρό κέρδος πιστότητας ροπών) — αν και είναι λιγότερο σταθερό εδώ και περιστασιακά αποκλίνει (κάνουμε clip την έξοδό του για να την κρατήσουμε πεπερασμένη).
- **Τα ευρήματα active-learning αντιστρέφονται**. Στο OULAD το uncertainty sampling είναι *χειρότερο* από το random (0.430 vs 0.460, $p = 0.01$) και ο RL agent *νικά* το uncertainty (0.462 vs 0.430, $p = 0.006$) — το αντίθετο του Realinho. (Υπό διόρθωση Holm εντός της οικογένειας OULAD η αντιστροφή RL παραμένει σημαντική, $p_{\text{holm}} = 0.041$ · η uncertainty-vs-random είναι οριακή, $p_{\text{holm}} = 0.059$ — διαβάζουμε και τις δύο ως κατευθυντικές.) Το demographics-only logistic uncertainty είναι κακά βαθμονομημένο εδώ, οπότε η entropy κατευθύνει λάθος τον προϋπολογισμό: μια καθαρή απόδειξη ότι τα συμπεράσματα AL εξαρτώνται από το dataset και δεν μεταφέρονται δωρεάν.
- **Η ποινή fairness δεν έχει σε τι να δαγκώσει**. Το base-rate χάσμα ανά gender του OULAD είναι μικροσκοπικό (withdrawal 0.305 vs 0.317), οπότε το Δ_{DP} ξεκινά στο 0.034 ± 0.020 και η ποινή $\lambda=1$ δεν το αλλάζει σημαντικά ($p = 0.43$). Η αξία της ποινής είναι πραγματική αλλά εξαρτώμενη από το να υπάρχει η απόκλιση για να αφαιρεθεί — ~ 0.20 στο Realinho, σχεδόν-μηδέν εδώ.

Augmenter (OULAD)	RF F1	XGB F1	MLP F1
Baseline (χωρίς oversampling)	0.355 $\pm$ 0.008	0.495 $\pm$ 0.007	0.477 $\pm$ 0.007
VAE	0.366 $\pm$ 0.011	0.323 $\pm$ 0.010	0.427 $\pm$ 0.025
Diffusion	0.365 $\pm$ 0.011	0.322 $\pm$ 0.010	0.423 $\pm$ 0.026
SMOTE	0.396 $\pm$ 0.007	0.479 $\pm$ 0.007	0.465 $\pm$ 0.006

Πίνακας 17: OULAD F1 πρόβλεψης withdrawal, μέσος $\pm$ std σε 10 seeds. Κανένας oversampler δεν βελτιώνει συνολικά το baseline· το VAE υποβαθμίζει αισθητά το XGBoost. Το χαμηλό απόλυτο F1 αντανακλά την demographics-only (behaviour-free) πρόβλεψη.



Σχήμα 19: OULAD — F1 oversampler ανά μοντέλο, μέσος $\pm$ std σε 10 seeds. Το generative oversampling δεν βοηθά και μπορεί να βλάψει (ιδίως το VAE στο XGBoost).

Συμπέρασμα. Τα σταθερά, model-agnostic ευρήματα (το oversampling δεν βοηθά· το diffusion ταιριάζει καλύτερα τη synthetic διασπορά) μεταφέρονται σε δύο πολύ διαφορετικά cohorts τριτοβάθμιας εκπαίδευσης· τα behaviour-sensitive (uncertainty sampling, η ποινή fairness) εξαρτώνται από ιδιότητες του dataset — τη βαθμονόμηση των prediction-scores και το μέγεθος του base-rate χάσματος, αντίστοιχα. Η αναφορά τόσο των αναπαραγωγών όσο και των αντιστροφών είναι πιο κατατοπιστική από μια ιστορία επιτυχίας ενός μόνο dataset.

7 Εντοπισμένες Προκλήσεις και οι Μετριάσμοί τους

Σχεδόν κάθε ποσοτική βελτίωση που αναφέρθηκε στην Ενότητα 6 ξεκίνησε ως *τρόπος αποτυχίας* ενός προηγούμενου, πιο συμβατικού σχεδιασμού. Αντί να περιγράψουμε μόνο το τελικό pipeline, αυτή η ενότητα αφηγείται τη διαδρομή από το αρχικό baseline έως την τελική του μορφή, οργανωμένη γύρω από τις τέσσερις αναβαθμίσεις στις οποίες τελικά δεσμεύτηκε το project. Πιστεύουμε ότι αυτή η τροχιά — ορατή μόνο όταν τρέξει κανείς ολόκληρο το pipeline δέκα φάσεων — είναι η κεντρική συνεισφορά της παρούσας εργασίας.

7.1 Αναβάθμιση 1: Από VAE σε TabDDPM diffusion

Σύμπτωμα. Η Φάση 3 χρησιμοποίησε ένα tabular Variational Auto-Encoder (Kostopoulos et al., 2025; Kingma and Welling, 2014) για να κάνει oversample τη μειοψηφική κλάση “dropout”. Το μοντέλο έφτασε σε ένα plateau ELBO σε περίπου 15 epochs (Σχήμα 4) και παρήγαγε δείγματα των οποίων οι *marginal μέσοι* ήταν κοντά στα πραγματικά δεδομένα ($\Delta_\mu \approx 0.06$), αλλά των οποίων οι *marginal τυπικές αποκλίσεις* ήταν συστηματικά συμπιεσμένες ($\Delta_\sigma \approx 0.27$, μια υποεκτίμηση διασποράς $\sim 27\%$ στην standardised κλίμακα). Οπτικά οι synthetic κατανομές στο Σχήμα 4 είναι πιο αιχμηρές από τις εμπειρικές, μια κλασική υπογραφή posterior over-confidence.

Διάγνωση. Το VAE με Gaussian decoder βελτιστοποιεί

$$\mathcal{L}_{\text{ELBO}} = \mathbb{E}_{q_\phi(\mathbf{z}|\mathbf{x})}[\log p_\theta(\mathbf{x}|\mathbf{z})] - \beta \text{KL}(q_\phi(\mathbf{z}|\mathbf{x}) \parallel p(\mathbf{z})), \quad (22)$$

που συνδέει το σφάλμα reconstruction με ένα μοναδικό global isotropic prior. Όταν το β είναι έστω και ελαφρώς μεγαλύτερο από τη βέλτιστη τιμή, ο όρος KL κυριαρχεί και το μοντέλο εμφανίζει *posterior*

collapse: ένα υποσύνολο των latents συγκλίνει στο prior, η effective latent διαστατικότητα συρρικνώνεται, και η υπονοούμενη ανά-χαρακτηριστικό διασπορά πέφτει. Ένα πιο λεπτό φαινόμενο αναλαμβάνει έπειτα για τις λίγες categorical στήλες (π.χ. *Daytime/evening attendance*, *Gender*): ο decoder, εκπαιδευμένος με Gaussian likelihood, πρέπει να προσεγγίσει μια δυαδική κατανομή με μια συνεχή και επιλέγει τον εμπειρικό μέσο ως την ασφαλή του mode — με άλλα λόγια, προβλέπει “0.7” αντί για “1”. Οι downstream classifiers το βλέπουν αυτό ως *soft χαρακτηριστικά που δεν εμφανίζονται ποτέ στο πραγματικό test set*, που είναι ακριβώς αυτό που εμφανίστηκε ως η μέτρια υποβάθμιση classifier που αναφέρθηκε στον Πίνακα 3.

Μετριάσμός. Αντικαταστήσαμε το VAE με ένα Tabular Denoising Diffusion Probabilistic Model (TabDDPM, [Kotelnikov et al., 2023](#)) προσαρμοσμένο από την οικογένεια DDPM ([Ho et al., 2020](#); [Sohl-Dickstein et al., 2015](#); [Nichol and Dhariwal, 2021](#); [Song et al., 2021](#)). Η forward διαδικασία εισάγει βαθμονομημένο Gaussian θόρυβο σε $T = 200$ βήματα,

$$q(\mathbf{x}_t | \mathbf{x}_0) = \mathcal{N}(\sqrt{\bar{\alpha}_t} \mathbf{x}_0, (1 - \bar{\alpha}_t) \mathbf{I}), \quad (23)$$

ενώ ένα μικρό MLP $\epsilon_\theta(\mathbf{x}_t, t)$ προβλέπει τον εισαγόμενο θόρυβο υπό το απλοποιημένο objective $\mathcal{L}_{\text{simple}} = \mathbb{E}_{t, \mathbf{x}_0, \epsilon} \|\epsilon - \epsilon_\theta(\mathbf{x}_t, t)\|_2^2$ ([Ho et al., 2020](#)). Για να χειριστούμε τα categorical blocks επαναφέρουμε (snap) κάθε denoised one-hot block στην επικρατέστερη κατηγορία του με argmax κατά τη δειγματοληψία, ώστε ο sampler να εκπέμπει ακριβή one-hot παρόμοια με μια συνεχή χαλάρωση (το VAE αντ’ αυτού δειγματοληπτεί τα decoder logits του μέσω Gumbel-Softmax ([Jang et al., 2017](#); [Maddison et al., 2017](#)), κάτι νόμιμο εκεί επειδή τα logits ορίζουν categorical κατανομή). Η αντικατάσταση του VAE generator με αυτόν τον diffusion sampler έκλεισε το χάσμα Δ_σ στο 0.126 ± 0.025 (Πίνακας 4), υποδιπλασιάζοντας με το παραπάνω το 0.271 ± 0.017 του VAE σε καθένα από τα δέκα seeds (paired Wilcoxon $p = 0.002$) — αν και, όπως τονίστηκε παραπάνω, με αντίστοιχο κόστος στο Δ_μ — και το argmax snap έλυσε εντελώς το categorical leakage (κανένα out-of-vocabulary value δεν εμφανίζεται στις ≈ 1186 synthetic γραμμές). Downstream, οι diffusion-augmented classifiers βρίσκονται ισάξιοι με τους VAE-augmented — η διαφορά F1 diffusion-vs-VAE είναι εντός ± 0.005 και μη σημαντική (Σχήμα 6) — οπότε η συνεισφορά του diffusion μοντέλου είναι στενή: καλύτερο ταίριασμα διασποράς, αντισταθμισμένο από χειρότερο ταίριασμα μέσου (χωρίς καθαρό κέρδος ροπών), όχι προβλεπτικό προβάδισμα σε αυτό το dataset.

Συμπέρασμα. Σε αυτό το dataset το πλεονέκτημα του diffusion generator έναντι του VAE είναι συγκεκριμένο, όχι καθολικό: (i) διατηρεί καλύτερα τη marginal διασπορά (με αντίστοιχο κόστος στους marginal μέσους, οπότε η καθαρή πιστότητα ροπών μένει αμετάβλητη), και (ii) ενσωματώνεται καθαρά με διακριτές στήλες όταν ο sampler κάνει snap κάθε block με argmax . Το εύρημα της διασποράς απηχεί τις παρατηρήσεις tabular-diffusion πιστότητας των [Kotelnikov et al. \(2023\)](#) (οι [Kostopoulos et al. \(2025\)](#) αναφέρουν μόνο downstream accuracy/F1/fairness, όχι κατανομική πιστότητα, οπότε δεν ισχυριζόμαστε echo πιστότητας εκεί), αν και η απλοποιημένη joint-Gaussian παραλλαγή μας δεν αναπαράγει τα καθολικά κέρδη πιστότητας του TabDDPM.

7.2 Αναβάθμιση 2: Από uncertainty sampling σε έναν Reinforcement-Learning DQN

Σύμπτωμα. Ο uncertainty-based active learner της Φάσης 5 ήδη ξεπερνούσε το random labelling (F1 0.795 ± 0.018 vs. 0.758 ± 0.025 σε δέκα seeds με τον ίδιο προϋπολογισμό, $p = 0.002$) και συνέκλινε σε περίπου έξι γύρους (Σχήμα 8). Ωστόσο, κατά την εξέταση, η στρατηγική ξόδεψε δυσανάλογο μερίδιο του προϋπολογισμού ετικετών της σε οριακά σημεία των οποίων η πληροφοριακή αξία ήταν επαναλαμβανόμενη — πολλά από αυτά βρίσκονταν κατά μήκος μιας στενής ζώνης του decision boundary — και σε σημεία που, μόλις επισημάνθηκαν, αναδιαμόρφωσαν μόνο οριακά τον classifier. Ο θεμελιώδης περιορισμός ήταν ότι η entropy είναι ένα σημειακό (point-wise) scalar· δεν μπορεί να προβλέψει πώς μια μελλοντική ετικέτα θα μετακινήσει τη global μετρική.

Διάγνωση. Το βέλτιστο active learning είναι, τυπικά, ένα πρόβλημα ακολουθιακής απόφασης του οποίου ο χώρος καταστάσεων είναι ο τρέχων classifier και ο χώρος δράσεων το unlabelled pool. Η επιδίωξη ενός μυωπικού, ανά-δείγμα heuristic — ακόμη και ενός καλά βαθμονομημένου — αγνοεί τόσο τις *batch αλληλεπιδράσεις* (η επισήμανση δύο όμοιων σημείων είναι σπατάλη) όσο και την *long-horizon credit* (μια ετικέτα μπορεί να βοηθήσει μόνο μέσω επόμενων).

Μετριάσμός. Ακολουθώντας την πρόσφατη βιβλιογραφία human-in-the-loop και RL-as-AL (Lazaros et al., 2026; Pang et al., 2018; Liu et al., 2018), αντικαταστήσαμε το heuristic με έναν Q-network agent (Mnih et al., 2015; Sutton and Barto, 2018). Για κάθε unlabelled σημείο υπολογίζουμε έναν πεντα-διάστατο descriptor (entropy, margin, απόσταση από το labelled centroid, προβλεπόμενη minority πιθανότητα, και nearest-neighbour απόσταση από το labelled σύνολο)· το *state* είναι ο ανά-χαρακτηριστικό μέσος, τυπική απόκλιση, μέγιστο, και 90ό percentile αυτών των descriptors σε όλο το pool ($5 \times 4 = 20$ διαστάσεις). Η *action* επιλέγει ένα από είκοσι strata ($5 \text{ features} \times 4 \text{ quantile buckets}$), από το οποίο αντλούνται τα $q = 20$ queries του γύρου, οπότε ο agent μαθαίνει ποια περιοχή του pool να δειγματοληπτεί σε ποιο καθεστώς. Κρισίμως, η reward είναι η μεταβολή στο test-set F_1 μετά από έναν γύρο επισήμανσης παρά το απόλυτο F_1 , που αφαιρεί ένα στατικό bias και εξουδετερώνει την παγίδα reward-hacking· το Q-network εκπαιδεύεται με Huber loss σε ομοιόμορφα δειγματοληπτημένα experience-replay mini-batches.

Παρατήρηση. Κατά μέσο όρο στα δέκα seeds το εκπαιδευμένο DQN έφτασε $F_1 0.761 \pm 0.020$ (Σχήμα 9) — στατιστικά ισόπαλο με το random acquisition (0.758) και ~ 3.4 μονάδες κάτω από το entropy baseline (0.795· paired Wilcoxon $p = 0.002$). Το μεμονωμένο split seed-42 το κολάκευσε στο 0.795· ο μέσος μεταξύ seeds το διορθώνει. Αυτό δείχνει ότι, με το μέτριο pool που χρησιμοποιείται εδώ ($\approx 3,278$ unlabelled γραμμές) και έναν μικρό προϋπολογισμό annotation (25 γύροι, 540 ετικέτες), το κόστος εξερεύνησης ενός πλουσιότερου action space δεν έχει ακόμη αποσβεστεί. Η greedy policy στην πραγματικότητα καταρρέει σε μία μόνο action και για τους 25 γύρους — σε αυτό το αντιπροσωπευτικό seed το stratum υψηλής απόστασης-από-το-centroid, αν και το κυρίως αρχο stratum ποικίλλει μεταξύ seeds (entropy-, margin-, ή distance-based) — οπότε διαβάζουμε την κατάρρευση, όχι το συγκεκριμένο stratum, ως τη συμπεριφορά στην οποία καταλήγει ο agent. Αυτό το αρνητικό-αλλά-διαφωτιστικό αποτέλεσμα έχει δύο επιπτώσεις: (i) η point-wise entropy είναι ένα ισχυρό baseline σε αυτά τα δεδομένα, και (ii) η RL διατύπωση γίνεται ελκυστική μόνο όταν το unlabelled pool είναι πολύ μεγαλύτερο και/ή ο labelling oracle είναι ετερογενής (πολλαπλοί annotators, μερικές ετικέτες, cost-sensitive ετικέτες). Καταφέραμε να αναδείξουμε αυτό το συμπέρασμα μόνο επειδή η reward του agent, η κατοχή του replay-buffer, και η ανά-γύρο action καταγράφονταν σε κάθε βήμα.

Συμπέρασμα. Το reinforcement learning δεν είναι δωρεάν νίκη έναντι του heuristic AL· η αξία του εξαρτάται από την κλίμακα του pool, την ομοιογένεια των labellers, και τον ορίζοντα της credit assignment. Το pipeline τώρα ποσοτικοποιεί αυτό το trade-off, που είναι από μόνο του θετική συνεισφορά.

7.3 Αναβάθμιση 3: Από post-hoc fairness σε in-processing fairness

Σύμπτωμα. Η Φάση 7 έλεγξε κάθε classifier των Φάσεων 2–4 ως προς το δυαδικό χαρακτηριστικό *Gender*. Τα χάσματα demographic-parity έφτασαν $\Delta_{DP} \approx 0.21$ και τα χάσματα equalised-odds έως $\Delta_{EqOdds} \approx 0.11$ (Σχήμα 11) — αποκλίσεις μεγάλες σε απόλυτους όρους: η μία ομάδα φύλου θα σηματοδευόταν για παρέμβαση περίπου 20 ποσοστιαίες μονάδες συχνότερα από την άλλη, κάτι δύσκολο να δικαιολογηθεί σε πραγματική ανάπτυξη. Η αφελής επανεξισορρόπηση του training set με diffusion-synthetic δείγματα (Ενότητα 7.1) έκλεισε το χάσμα F_1 αλλά δεν έκλεισε το χάσμα DP, επειδή ο synthetic generator εξακολουθούσε να κληρονομεί τη δομική μεροληψία των αρχικών δεδομένων.

Διάγνωση. Ο κλασικός Bayes-optimal classifier σε μια μεροληπτική κατανομή δεδομένων είναι ο ίδιος μεροληπτικός· καμία ποσότητα distribution-matching augmentation δεν μπορεί να αφαιρέσει τη μεροληψία εκτός αν ο generator εξαρτάται (conditioned) από την ταυτότητα ομάδας. Το post-hoc thresholding, από την άλλη, θυσιάζει μεγάλη ποσότητα accuracy επειδή οι υποκείμενες κατανομές score για τις δύο ομάδες είναι ήδη κακά βαθμονομημένες.

Μετριάσμός. Αναδιατυπώνουμε την εκπαίδευση ταξινόμησης ως μια βελτιστοποίηση δύο στόχων (Raftopoulos et al., 2025a; Agarwal et al., 2018; Zafar et al., 2017; Hardt et al., 2016),

$$\min_{\theta} \mathcal{L}_{\text{CE}}(\theta) + \lambda |\Delta_{\text{DP}}(\theta)|, \quad (24)$$

όπου το surrogate $\tilde{\Delta}_{\text{DP}}(\theta) = |\bar{y}_a - \bar{y}_b|$, η απόλυτη διαφορά των μέσων sigmoid εξόδων μεταξύ των προστατευόμενων ομάδων εντός ενός mini-batch, αντικαθιστά τη μη-διαφορίσιμη απόκλιση. Δύο λεπτομέρειες υλοποίησης αποδείχθηκαν ουσιώδεις.

Πρώτον, διαπιστώσαμε ότι για πολύ μικρά batches μια ομάδα μπορεί να μείνει χωρίς εκπροσώπηση, κάτι που παράγει ένα θορυβώδες ή μη-ορισμένο surrogate. Το μετριάσαμε υπολογίζοντας την ποινή demographic-parity *μόνο* σε mini-batches που περιέχουν και τις δύο προστατευόμενες ομάδες, παραλείποντας τη συνεισφορά της διαφορετικά· τα ίδια τα batches αντλούνται με συνηθισμένο shuffling.

Δεύτερον, το surrogate είναι μια *soft* απόκλιση, ενώ αναφέρουμε τη *hard* απόκλιση κατά την αξιολόγηση ($\Delta_{\text{DP}} = |p(\hat{y} = 1 | a) - p(\hat{y} = 1 | b)|$). Η απεικόνιση από soft σε hard εξαρτάται από το operating threshold· επαληθεύσαμε εμπειρικά ότι, σε όλο το sweep $\lambda \in \{0, 0.1, 0.5, 1, 2, 5, 10\}$ (Σχήμα 12), οι δύο ποσότητες ακολουθούν η μία την άλλη στο χαμηλό-έως-μέτριο εύρος, οπότε το λ λειτουργεί ως χρησιμοποιήσιμο κουμπί (το hard-decision Δ_{DP} μπορεί να αναπηδήσει στο μεγαλύτερο λ , όπως σημειώθηκε στην Ενότητα 6).

Παρατήρηση. Στα δέκα seeds, η ενεργοποίηση της ποινής μειώνει σταθερά την απόκλιση: στο $\lambda = 1$, το Δ_{DP} πέφτει από 0.211 ± 0.035 (στο $\lambda = 0$) σε 0.083 ± 0.039 — μείωση $\sim 60\%$ σε κάθε seed (paired Wilcoxon $p = 0.002$) — με κόστος ~ 1.6 μονάδες accuracy ($0.854 \rightarrow 0.838$) και λίγες μονάδες F1 (Πίνακας 12). Το trade-off είναι επομένως πραγματικό, όχι δωρεάν. Δύο ειλικρινείς επιφυλάξεις μετριάζουν την ανάγνωση ενός μόνο seed. Πρώτον, το εμπειρικό frontier δεν είναι ελεύθερο dominated σημείων: στον μέσο μεταξύ seeds το $\lambda = 1$ είναι αυστηρά dominated από το $\lambda = 5$, και το $\lambda \approx 2-5$ είναι η περιοχή που πραγματικά ιχνηλατεί το frontier (Σχήμα 13). Δεύτερον, η ακριβής διασταύρωση είναι ευαίσθητη στο seed ($\sigma_{\Delta_{\text{DP}}} \approx 0.04$ στο $\lambda = 1$), οπότε το λ θα έπρεπε να επιλέγεται έναντι ενός στόχου ανώτατου ορίου απόκλισης παρά να καθιλώνεται σε μία “βέλτιστη” τιμή. Με αυτές τις επιφυλάξεις, μια μοναδική hyper-parameter που ελέγχει ένα βαθμονομημένο trade-off fairness/accuracy παραμένει το πιο πρακτικά χρήσιμο artefact του project.

Συμπέρασμα. Το in-processing fairness, διατυπωμένο ως ένα διαφορίσιμο surrogate προστιθέμενο στην loss, κυριαρχεί τόσο του post-hoc thresholding όσο και του bias-blind augmentation σε αυτό το dataset. Το αποτέλεσμα είναι συνεπές με τις θεωρητικές reductions των Agarwal et al. (2018) και τα πειραματικά συμπεράσματα των Raftopoulos et al. (2025a)· η αναφορά του frontier ως μιας λ -δεικτοδοτημένης περιοχής αντί ενός μοναδικού σημείου λειτουργίας απαντά επίσης στο ίδιο τους το κάλεσμα για ανάλυση ευαισθησίας hyper-parameter έναντι σταθερών defaults (η §9.1, §9.3 τους).

7.4 Αναβάθμιση 4: Από tabular-only σε multimodal DistilBERT χαρακτηριστικά

Σύμπτωμα. Ακόμη και μετά τις Φάσεις 4–8 το κύριο F1 ήταν περιορισμένο κοντά στο 0.82, με τους classifiers επίμονα μπερδεμένους στο υποσύνολο των οριακών φοιτητών “at-risk-but-not-dropped”. Η εξέταση των κατατάξεων feature-importance (XGBoost gain) αποκάλυψε ότι οι πιο χρήσιμες στήλες ήταν αυτές της ακαδημαϊκής επίδοσης, ενώ τα *συμπεριφορικά* σήματα απουσίαζαν από το dataset.

Στην πράξη τα πανεπιστήμια συλλέγουν ολοένα και περισσότερο τέτοια σήματα ως feedback ελεύθερου κειμένου ή σχόλια LMS (Raftopoulos et al., 2025b).

Διάγνωση. Στο dataset λείπει μια modality, όχι μια στήλη. Καμία επανεξισορρόπηση, re-weighting, ή ποινή fairness δεν μπορεί να ανακτήσει πληροφορία που δεν καταγράφηκε ποτέ.

Μετριάσμος. Κατασκευάσαμε μια προσομοίωση feedback ελεύθερου κειμένου (ένα σύντομο σχόλιο ανά φοιτητή, παραγόμενο από ένα sentiment template που συσχετίζεται ήπια με την ετικέτα) και κωδικοποιήσαμε κάθε σχόλιο με ένα frozen DistilBERT μοντέλο (Sanh et al., 2019; Devlin et al., 2019; Vaswani et al., 2017). Εξάγαμε mean-pooled 768-D embeddings, τα μειώσαμε σε 32 principal components μόνο στο *training* partition — κρίσιμω, η βάση PCA (και ένας επακόλουθος scaler) είναι έπειτα *frozen* και εφαρμόζονται αμετάβλητα στα test embeddings για την αποτροπή leakage — και συνενώσαμε τα components με τα tabular χαρακτηριστικά. Τα Random Forest, XGBoost, και ένα MLP επανεκπαιδεύτηκαν στα multimodal διανύσματα. Κατά μέσο όρο σε δέκα seeds, το F1 του Random Forest ανέβηκε από 0.780 σε 0.840 και το AUC από 0.919 σε 0.956, με κάθε μοντέλο να κερδίζει ~ 0.06 F1 (όλα paired $p = 0.002$ · Πίνακας 13, Σχήμα 14).

Τρεις δικλείδες υλοποίησης ήταν ουσιώδεις. Πρώτον, ο DistilBERT encoder κρατήθηκε *frozen*· δεν τον κάναμε fine-tune στις ετικέτες, επειδή αυτό θα δημιουργούσε ένα label-leaking κανάλι κειμένου. Δεύτερον, το PCA και ο scaler προσαρμόστηκαν αυστηρά στο training partition του μοναδικού 75/25 split και έπειτα εφαρμόστηκαν αμετάβλητα στα test σχόλια, αντικατοπτρίζοντας μια ανάπτυξη στην οποία τα test σχόλια είναι αόρατα κατά τον χρόνο PCA-fit. Τρίτον, το simulated κείμενο παρήχθη με βαθμονομημένο θόρυβο ώστε το multimodal κέρδος να μην είναι κενό (δηλ. όχι απλώς ένα ντετερμινιστικό αντίγραφο της ετικέτας).

Επιφύλαξη. Οι αριθμοί στη Φάση 9 επομένως αντιπροσωπεύουν μια *οροφή* του τι θα μπορούσε να επιτύχει μια multimodal επέκταση μόλις γίνει διαθέσιμο ένα γνήσιο κανάλι κειμένου. Το μεθοδολογικό pipeline — frozen encoder, train-only PCA, fold-aware concatenation — είναι παρ’ όλα αυτά άμεσα μεταφέρσιμο.

Συμπέρασμα. Μια modality-agnostic, leakage-safe επέκταση κειμένου βελτιώνει ουσιαστικά την πρόβλεψη εγκατάλειψης με τρόπο που καμία ποσότητα tabular modelling δεν θα μπορούσε. Αυτό το εύρημα ευθυγραμμίζεται με την multimodal MOOC ανάλυση των Raftopoulos et al. (2025b) και υποδηλώνει ότι το text feedback είναι μια υπο-αξιοποιημένη modality στην higher-ed analytics.

7.5 Άλλες παρατηρήσεις και συγκρίσεις εκτός εμβέλειας

Πέρα από τις τέσσερις κύριες αναβαθμίσεις, τρία επιπλέον σημεία διαμόρφωσαν τον σχεδιασμό και οριοθέτησαν την εμβέλεια της παρούσας μελέτης.

(a) Η ανισορροπία κλάσεων είναι μέτρια, όχι ακραία. Η κλάση dropout είναι $\sim 32\%$ του cohort (Σχήμα 1), ήπια σε σχέση με τυπικά imbalanced-learning benchmarks· βασιζόμαστε επομένως σε class weighting (class_weight / scale_pos_weight) παρά σε επιθετικό resampling για τα baselines. Η αρχική πρόταση προέβλεπε σύγκριση του generative oversampler έναντι ενός παραδοσιακού oversampler όπως το SMOTE (Chawla et al., 2002)· συμπεριλαμβανούμε αυτό το head-to-head ablation εδώ (Φάση 3b, Ενότητα 4.2.4), τρέχοντας το SMOTE μέσω του πανομοιότυπου classifier pipeline με τους VAE και diffusion augmenters ώστε τα τρία να είναι άμεσα συγκρίσιμα.

(b) Από single-seed σε multi-seed. Οι ανά-φάση πίνακες αναφέρονται στο κανονικό σταθερό split (RANDOM_SEED= 42) για ακριβή αναπαραγωγικότητα, αλλά δεν βασιζόμαστε πλέον μόνο σε αυτό: επαναλαμβάνουμε ολόκληρο το pipeline σε δέκα seeds και αναφέρουμε μέσο $\pm$ std με paired

τεστ σημαντικότητας (Ενότητες 5.4 και 6.14). Αυτό είναι που μας επιτρέπει να πούμε ποια φαινόμενα επιβιώνουν της μεταβολής seed-και-split – και, όπως αποδεικνύεται, το single-seed σημείο λειτουργίας της Φάσης-8 είναι το λιγότερο σταθερό νούμερο της μελέτης και πρέπει να διαβάζεται μέσω της διασποράς του μεταξύ seeds παρά ως σημειακή εκτίμηση.

(c) Βαθμονόμηση πιθανοτήτων. Αναφέρουμε threshold-based προβλεπτικές και fairness μετρικές αλλά δεν βαθμονομούμε ξεχωριστά τις post-augmentation εκτιμήσεις πιθανότητας. Η calibration-aware μετα-επεξεργασία (π.χ. Platt ή temperature scaling σε ένα held-out fold) είναι μια γνωστή βελτίωση για augmented tree ensembles και αφήνεται ως μελλοντική εργασία.

8 Συμπεράσματα και Μελλοντική Εργασία

Παρουσιάσαμε ένα end-to-end pipeline δέκα φάσεων για την πρόβλεψη εγκατάλειψης φοιτητών που ενσωματώνει generative oversampling, reinforcement-learned active sampling, in-processing fairness, και multimodal text augmentation, με κάθε συγκριτικό ισχυρισμό επικυρωμένο σε δέκα τυχαία seeds. Το εμπειρικό κύριο σημείο είναι ότι **το ισχυρότερο multimodal μοντέλο (XGBoost + DistilBERT) φτάνει $F1 = 0.852 \pm 0.009$ και $AUC = 0.961 \pm 0.005$ — ένα σταθερό ~ 0.06 κέρδος $F1$ έναντι του tabular baseline ($p = 0.002$) — ενώ μια in-processing ποινή στο $\lambda = 1$ μειώνει το demographic-parity χάσμα από 0.211 σε 0.083 ($\sim 60\%$, $p = 0.002$) με κόστος ~ 1.6 μονάδες accuracy.** Αυτά τα νούμερα λειτουργικοποιούν τα ποιοτικά trade-offs που τεκμηριώνονται στις τέσσερις αναφορές MDPI που υποκίνησαν το project· επειδή το κείμενο της Φάσης-9 είναι simulated, το multimodal νούμερο είναι μια ποσοτικοποιημένη οροφή (το synthetic κείμενο εισάγει μόνο 0.28 bits για το label, Ενότητα 6.11), όχι αναπτύξιμο αποτέλεσμα — και δείχνουμε ότι οι σύγχρονες open-data “multimodal-dropout” εναλλακτικές στηρίζονται στην ίδια συσκευή synthetic κειμένου, μόνο αδημοσίευτα (Ενότητα 6.12).

Εξίσου σημαντικό, το pipeline δίνει μια ποσοτική απάντηση σε καθένα από τα τέσσερα ερευνητικά ερωτήματα που τέθηκαν στην Ενότητα 1:

- **RQ1 (Generative SSL).** Το TabDDPM-based diffusion διατηρεί καλύτερα τη marginal διασπορά των synthetic δεδομένων (Δ_σ υποδιπλασιασμένο, $p = 0.002$) και χειρίζεται καθαρά τις δυαδικές στήλες via Gumbel-Softmax, αλλά αυτό το κέρδος διασποράς αντισταθμίζεται από μια εξίσου σημαντική χειροτέρευση του marginal μέσου (Δ_μ), αφήνοντας την καθαρή πιστότητα ροπών αμετάβλητη· και δεν βοηθά το downstream classifier $F1$, όπου είναι στατιστικά ισάξιο τόσο με το VAE όσο και με το κλασικό SMOTE. Σε ένα dataset με 32% μειοψηφία, το oversampling οποιουδήποτε είδους αγοράζει ελάχιστο predictive lift· η συνεισφορά είναι μεθοδολογική.
- **RQ2 (Active learning).** Το uncertainty sampling είναι ένα ισχυρό baseline· μια RL/DQN επέκταση δικαιολογείται μόνο σε μεγαλύτερα μεγέθη unlabelled-pool και μακρύτερους ορίζοντες απ’ ό,τι επιτρέπει το παρόν cohort.
- **RQ3 (Fairness).** Τα in-processing διαφορίσιμα surrogates κυριαρχούν του post-hoc και του augmentation-based μετριασμού: η ποινή μειώνει σταθερά την demographic-parity απόκλιση ($p = 0.002$) εκεί που το augmentation δεν το κάνει. Το trade-off accuracy/fairness είναι γνήσιο αλλά όχι δωρεάν, και το σημείο λειτουργίας επιλέγεται καλύτερα ως περιοχή ($\lambda \approx 2-5$) παρά ως μία τιμή, καθώς η ακριβής διασταύρωση είναι ευαίσθητη στο seed.
- **RQ4 (Multimodality).** Ένα pipeline frozen DistilBERT + train-only PCA κλείνει το μεγαλύτερο μέρος του υπολειπόμενου χάσματος accuracy, υπό την προϋπόθεση ότι επιβάλλεται ένα leakage-safe protocol.

Εξωτερική εγκυρότητα. Η αναπαραγωγή ολόκληρου του pipeline σε ένα δεύτερο cohort (OULAD, Ενότητα 6.15) δείχνει ότι τα model-agnostic συμπεράσματα ταξιδεύουν — κανέναν oversampler

δεν βοηθά (το VAE μάλιστα βλάπτει το XGBoost), και το diffusion ξανά ταιριάζει καλύτερα τη synthetic διασπορά — ενώ τα behaviour-sensitive όχι: το uncertainty sampling εκεί υπολείπεται του random, και η ποιινή fairness δεν έχει απόκλιση να αφαιρέσει. Ξεχωριστά, το leakage-safe DistilBERT protocol φτάνει AUC ≈ 0.82 σε ένα πραγματικό σώμα εκπαιδευτικού κειμένου σε έξι annotated constructs (Ενότητα 6.11), επικυρώνοντας τον multimodal μηχανισμό σε γνήσιο φοιτητικό γραπτό αν και το dropout-linked κείμενο δεν είναι διαθέσιμο. Ένα self-labelled SSL baseline (Co-Forest) στα δύο cohorts (Ενότητα 6.7) δείχνει την ίδια εξάρτηση-από-το-dataset: ανακτά το μεγαλύτερο μέρος του supervised F1 από 1–10% των ετικετών, αλλά νικά ένα balanced supervised seed μόνο στο OULAD, όπου το supervised σήμα είναι ασθενές — όχι στο Realinho.

Περιορισμοί. Η text modality στη Φάση 9 είναι simulated· πραγματικό LMS ή feedback κείμενο πιθανότατα θα απέδιδε μικρότερα κέρδη από την οροφή που αναφέρεται εδώ. Ο προϋπολογισμός active-learning ήταν μικρός (ένας oracle 25 γύρων, 540 ετικετών), και δεν δοκιμάσαμε mixed-modality active learning. Τέλος, το fairness αξιολογήθηκε μόνο ως προς το δυαδικό χαρακτηριστικό *Gender*· άλλες προστατευόμενες διαστάσεις (π.χ. ηλικία, εθνικότητα) και intersectional αποκλίσεις (Mehrabian et al., 2021) δεν εξετάστηκαν.

Μελλοντική εργασία. Τρεις επεκτάσεις είναι άμεσα εφικτές: (i) conditional diffusion στα προστατευόμενα χαρακτηριστικά για να ελεγχθεί αν το fairness μπορεί να επαχθεί κατά τον χρόνο παραγωγής παρά κατά τον χρόνο εκπαίδευσης· (ii) μια διατύπωση contextual-bandit AL που μπορεί να αποδειχθεί πιο sample-efficient από το DQN στο καθεστώς μικρού pool· και (iii) η ανάπτυξη του pipeline σε ένα πραγματικό θεσμικό cohort με συναινετικά σχόλια feedback, που θα έλεγχε άμεσα την multimodal οροφή που αναφέρεται εδώ.

Ευχαριστίες

Ο συγγραφέας ευχαριστεί τους maintainers του dataset *Predict Students Dropout and Academic Success* (Realinho et al., 2022; Martins et al., 2021) και την open-access κοινότητα της MDPI που διέθεσε ελεύθερα τις τέσσερις βασικές εργασίες (Kostopoulos et al., 2025; Raftopoulos et al., 2025b; Lazaros et al., 2026; Raftopoulos et al., 2025a), που κατέστησαν αυτό το project δυνατό.

Αναφορές

Alekh Agarwal, Alina Beygelzimer, Miroslav Dudík, John Langford, and Hanna Wallach. A reductions approach to fair classification. In *Proceedings of the 35th International Conference on Machine Learning (ICML)*, 2018.

Akshay Agrawal and Andreas Paepcke. The Stanford MOOC posts dataset. <http://infolab.stanford.edu/~paepcke/stanfordMOOCForumPostsSet.tar.gz>, 2014.

Naif Radi Aljohani, Ayman Fayoumi, and Saeed-Ul Hassan. Predicting at-risk students using clickstream data in the virtual learning environment. *Sustainability*, 11(24):7238, 2019.

Joanna Alvarado-Urbe, Paola Mejía-Almada, Ana Luisa Masetto Herrera, Roland Molontay, Isabel Hilliger, Vinayak Hegde, José Enrique Montemayor Gallegos, Renato Armando Ramírez Díaz, and Hector G. Ceballos. Student dataset from Tecnológico de Monterrey in Mexico to predict dropout in higher education. *Data*, 7(9):119, 2022. doi: 10.3390/data7090119.

Leo Breiman. Random forests. *Machine Learning*, 45(1):5–32, 2001.

Nitesh V. Chawla, Kevin W. Bowyer, Lawrence O. Hall, and W. Philip Kegelmeyer. SMOTE: Synthetic minority over-sampling technique. *Journal of Artificial Intelligence Research*, 16:321–357, 2002.

- Tianqi Chen and Carlos Guestrin. XGBoost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 785–794, 2016.
- Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. BERT: Pre-training of deep bidirectional transformers for language understanding. In *Proceedings of NAACL-HLT*, pages 4171–4186, 2019.
- Meng Fang, Yuan Li, and Trevor Cohn. Learning how to active learn: A deep reinforcement learning approach. In *Proceedings of the 2017 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 595–605, 2017.
- Rong Gao and Qin Ni. FairEduNet: A novel adversarial network for fairer educational dropout prediction. *Scientific Reports*, 15, 2025. doi: 10.1038/s41598-025-13632-w.
- Josh Gardner, Christopher Brooks, Juan Miguel Andres, and Ryan S. Baker. MORF: A framework for predictive modeling and replication at scale with privacy-restricted MOOC data. In *Proceedings of the IEEE International Conference on Big Data (Big Data)*, 2018. arXiv:1801.05236.
- Moritz Hardt, Eric Price, and Nathan Srebro. Equality of opportunity in supervised learning. In *Advances in Neural Information Processing Systems (NeurIPS)*, pages 3315–3323, 2016.
- Jonathan Ho, Ajay Jain, and Pieter Abbeel. Denoising diffusion probabilistic models. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 33, pages 6840–6851, 2020.
- Eric Jang, Shixiang Gu, and Ben Poole. Categorical reparameterization with Gumbel-Softmax. In *International Conference on Learning Representations (ICLR)*, 2017.
- Diederik P. Kingma and Jimmy Ba. Adam: A method for stochastic optimization. In *International Conference on Learning Representations (ICLR)*, 2015.
- Diederik P. Kingma and Max Welling. Auto-Encoding Variational Bayes. In *Proceedings of the 2nd International Conference on Learning Representations (ICLR)*, 2014.
- Georgios Kostopoulos, Nikos Fazakis, Sotiris Kotsiantis, and Yiannis Dimakopoulos. Enhancing semi-supervised learning in educational data mining through synthetic data generation using tabular variational autoencoder. *Algorithms*, 18(10):663, 2025. doi: 10.3390/a18100663. URL <https://www.mdpi.com/1999-4893/18/10/663>.
- Akim Kotelnikov, Dmitry Baranchuk, Ivan Rubachev, and Artem Babenko. TabDDPM: Modelling tabular data with diffusion models. In *Proceedings of the 40th International Conference on Machine Learning (ICML)*, volume 202 of PMLR, pages 17564–17579, 2023.
- Jakub Kuzilek, Martin Hlosta, and Zdenek Zdrahal. Open university learning analytics dataset. *Scientific Data*, 4:170171, 2017. doi: 10.1038/sdata.2017.171.
- Konstantinos Lazaros, Aristidis G. Vrahatis, and Sotiris Kotsiantis. Human-in-the-loop artificial intelligence: A systematic review of concepts, methods, and applications. *Entropy*, 28(4):377, 2026. doi: 10.3390/e28040377. URL <https://www.mdpi.com/1099-4300/28/4/377>.
- David D. Lewis and William A. Gale. A sequential algorithm for training text classifiers. In *Proceedings of the 17th Annual International ACM SIGIR Conference on Research and Development in Information Retrieval*, pages 3–12, 1994.
- Ming Li and Zhi-Hua Zhou. Improve computer-aided diagnosis with machine learning techniques using undiagnosed samples. *IEEE Transactions on Systems, Man, and Cybernetics — Part A: Systems and Humans*, 37(6):1088–1098, 2007. doi: 10.1109/TSMCA.2007.904745.

- Ming Liu, Wray Buntine, and Gholamreza Haffari. Learning how to actively learn: A deep imitation learning approach. In *Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (ACL), Volume 1: Long Papers*, pages 1874–1883, 2018.
- Chris J. Maddison, Andriy Mnih, and Yee Whye Teh. The concrete distribution: A continuous relaxation of discrete random variables. In *International Conference on Learning Representations (ICLR)*, 2017.
- Mónica V. Martins, Daniel Tolledo, Jorge Machado, Luís M. T. Baptista, and Valentim Realinho. Early prediction of student’s performance in higher education: A case study. In *Trends and Applications in Information Systems and Technologies (WorldCIST 2021)*, volume 1365 of *Advances in Intelligent Systems and Computing*, pages 166–175. Springer, 2021. doi: 10.1007/978-3-030-72657-7_16.
- Ninareh Mehrabi, Fred Morstatter, Nripsuta Saxena, Kristina Lerman, and Aram Galstyan. A survey on bias and fairness in machine learning. *ACM Computing Surveys*, 54(6):1–35, 2021.
- Miloud Mihoubi, Meriem Zerkouk, and Belkacem Chikhaoui. Beyond classical and contemporary models: A transformative AI framework for student dropout prediction in distance learning using RAG, prompt engineering, and cross-modal fusion, 2025. arXiv:2507.05285; public MIT repo (UCI Realinho base + GPT-4.5 synthetic student comments).
- Volodymyr Mnih, Koray Kavukcuoglu, David Silver, Andrei A. Rusu, Joel Veness, et al. Human-level control through deep reinforcement learning. *Nature*, 518(7540):529–533, 2015.
- Alexander Quinn Nichol and Prafulla Dhariwal. Improved denoising diffusion probabilistic models. In *Proceedings of the 38th International Conference on Machine Learning (ICML)*, volume 139 of *Proceedings of Machine Learning Research*, pages 8162–8171, 2021.
- Kunkun Pang, Mingzhi Dong, Yang Wu, and Timothy M. Hospedales. Meta-learning transferable active learning policies by deep reinforcement learning. In *AutoML Workshop at the 35th International Conference on Machine Learning (ICML)*, 2018.
- F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, P. Prettenhofer, R. Weiss, V. Dubourg, J. Vanderplas, A. Passos, D. Cournapeau, M. Brucher, M. Perrot, and E. Duchesnay. Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12:2825–2830, 2011.
- George Raftopoulos, Nikos Fazakis, Gregory Davrazos, and Sotiris Kotsiantis. A comprehensive review and benchmarking of fairness-aware variants of machine learning models. *Algorithms*, 18(7):435, 2025a. doi: 10.3390/a18070435. URL <https://www.mdpi.com/1999-4893/18/7/435>.
- George Raftopoulos, Georgios Kostopoulos, Gregory Davrazos, Theodor Panagiotakopoulos, Sotiris Kotsiantis, and Achilles Kameas. Comparative analysis of self-labeled algorithms for predicting mooc dropout: A case study. *Applied Sciences*, 15(22):12025, 2025b. doi: 10.3390/app152212025. URL <https://www.mdpi.com/2076-3417/15/22/12025>.
- Valentim Realinho, Jorge Machado, Luís Baptista, and Mónica V. Martins. Predicting student dropout and academic success. *Data*, 7(11):146, 2022.
- Pengzhen Ren, Yun Xiao, Xiaojun Chang, Po-Yao Huang, Zhihui Li, Brij B. Gupta, Xiaojiang Chen, and Xin Wang. A survey of deep active learning. *ACM Computing Surveys*, 54(9):1–40, 2021.
- Cristobal Romero and Sebastián Ventura. Educational data mining and learning analytics: An updated survey. *WIREs Data Mining and Knowledge Discovery*, 10(3):e1355, 2020.

- Victor Sanh, Lysandre Debut, Julien Chaumond, and Thomas Wolf. DistilBERT, a distilled version of BERT: smaller, faster, cheaper and lighter. *arXiv preprint arXiv:1910.01108*, 2019.
- Burr Settles. Active learning literature survey. Technical Report 1648, University of Wisconsin-Madison, 2009.
- Jascha Sohl-Dickstein, Eric A. Weiss, Niru Maheswaranathan, and Surya Ganguli. Deep unsupervised learning using nonequilibrium thermodynamics. In *Proceedings of the 32nd International Conference on Machine Learning (ICML)*, 2015.
- Yang Song, Jascha Sohl-Dickstein, Diederik P. Kingma, Abhishek Kumar, Stefano Ermon, and Ben Poole. Score-based generative modeling through stochastic differential equations. In *Proceedings of the 9th International Conference on Learning Representations (ICLR)*, 2021.
- Richard S. Sutton and Andrew G. Barto. *Reinforcement Learning: An Introduction*. MIT Press, Cambridge, MA, 2nd edition, 2018.
- Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. *Advances in Neural Information Processing Systems (NeurIPS)*, 2017.
- Valdemar Švábenský, Ryan S. Baker, Andrés Zambrano, Yishan Zou, and Stefan Slater. Towards Generalizable Detection of Urgency of Discussion Forum Posts. In *Proceedings of the 16th International Conference on Educational Data Mining (EDM)*, pages 302–309. International Educational Data Mining Society, 2023. doi: 10.5281/zenodo.8115790.
- Lei Xu, Maria Skoularidou, Alfredo Cuesta-Infante, and Kalyan Veeramachaneni. Modeling tabular data using conditional GAN. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2019.
- Jifan Yu et al. MOOCCubeX: A large knowledge-centered repository for adaptive learning in MOOCs. In *Proceedings of the 30th ACM International Conference on Information and Knowledge Management (CIKM)*, pages 4643–4652. ACM, 2021. doi: 10.1145/3459637.3482010.
- Muhammad Bilal Zafar, Isabel Valera, Manuel Gomez-Rodriguez, and Krishna P. Gummadi. Fairness constraints: Mechanisms for fair classification. In *Proceedings of the 20th International Conference on Artificial Intelligence and Statistics (AISTATS)*, pages 962–970, 2017.
- Meriem Zerkouk, Miloud Mihoubi, and Belkacem Chikhaoui. SentiDrop: A multi-modal machine learning model for predicting dropout in distance learning. *arXiv preprint arXiv:2507.10421*, 2025.

A' Αποσπάσματα Κώδικα Υλοποίησης

Για πλήρη αναπαραγωγικότητα, τα πιο καθοριστικά αποσπάσματα κώδικα που αναφέρονται στις Ενότητες 4 και 7 αναπαράγονται (ελαφρώς συντομευμένα) παρακάτω. Το πλήρες δέντρο πηγαιού κώδικα (δέκα phase scripts συν το κοινό module `common.py`) περιλαμβάνεται στο συνοδευτικό repository· οι φάσεις καλούνται με τη σειρά (Listing 7).

1.1 Κοινό module προεπεξεργασίας (`common.py`)

Το module `common.py` καρφώνει το global seed (`RANDOM_SEED = 42`), ορίζει το κανονικό *stratified* 75/25 train/test split, προσαρμόζει τον one-hot encoder και τον standard scaler *μόνο στο training partition* (αποτρέποντας leakage), διατηρεί τα encoded arrays ώστε κάθε επόμενη φάση να καταναλώνει το πανομοιότυπο split, και εκθέτει τους κοινούς βοηθούς predictive- και fairness-metric. Αυτό εγγυάται ότι όλοι οι αναφερόμενοι αριθμοί υπολογίζονται σε ένα σταθερό evaluation cohort.

```

1 import numpy as np, os
2 from pathlib import Path
3 from sklearn.model_selection import train_test_split
4 from sklearn.preprocessing import StandardScaler, OneHotEncoder
5
6 RANDOM_SEED = 42
7 np.random.seed(RANDOM_SEED)
8 PROTECTED_ATTR = "Gender"      # binary sensitive attribute
9 TARGET_COL = "Target"
10
11 def preprocess(df, test_size=0.25):
12     df = make_binary_target(df)          # y = 1[Target == "Dropout"]
13     numerical_cols = [c for c in df.columns
14                       if c not in CATEGORICAL_COLS + [TARGET_COL, "y"]]
15     X_df, y = df[CATEGORICAL_COLS + numerical_cols].copy(), df["y"].values
16
17     # Stratified split BEFORE fitting any transformer -> no Leakage
18     X_tr, X_te, y_tr, y_te = train_test_split(
19         X_df, y, test_size=test_size, stratify=y,
20         random_state=RANDOM_SEED)
21     s_tr, s_te = X_tr[PROTECTED_ATTR].values, X_te[PROTECTED_ATTR].values
22
23     ohe = OneHotEncoder(handle_unknown="ignore", sparse_output=False)
24     cat_tr = ohe.fit_transform(X_tr[CATEGORICAL_COLS]) # fit on TRAIN
25     cat_te = ohe.transform(X_te[CATEGORICAL_COLS])
26     scaler = StandardScaler()
27     num_tr = scaler.fit_transform(X_tr[numerical_cols]) # fit on TRAIN
28     num_te = scaler.transform(X_te[numerical_cols])
29
30     X_train = np.concatenate([num_tr, cat_tr], 1).astype(np.float32)
31     X_test = np.concatenate([num_te, cat_te], 1).astype(np.float32)
32     cat_card = [len(c) for c in ohe.categories_] # one-hot block sizes
33     # everything downstream needs, bundled in one dict; these keys are the
34     # cross-phase contract the later phases index into, so they stay stable.
35     return {"X_train": X_train, "X_test": X_test,
36            "y_train": y_tr, "y_test": y_te, "s_train": s_tr, "s_test": s_te,
37            "num_numerical": len(numerical_cols), "cat_card": cat_card,
38            "scaler": scaler, "ohe": ohe} # (+ feature_names, numerical_cols)
39
40 def fairness_metrics(y_true, y_pred, s):
41     g0, g1 = (s == 0), (s == 1)
42     # group-conditioned rates; an empty group returns NaN, never a fake "0"
43     rate = lambda m: y_pred[m].mean() if m.any() else np.nan
44     tpr = lambda m: y_pred[m & (y_true == 1)].mean() if (m & (y_true == 1)).any()
45             else np.nan
46     fpr = lambda m: y_pred[m & (y_true == 0)].mean() if (m & (y_true == 0)).any()
47             else np.nan

```

```

46 eod = abs(tpr(g1) - tpr(g0))
47 return {"demographic_parity_diff": abs(rate(g1) - rate(g0)),
48         "equal_opportunity_diff": eod,
49         "equalized_odds_diff": max(eod, abs(fpr(g1) - fpr(g0)))}
50 # (+ fpr_diff, accuracy_diff, per-group selection & accuracy rates)

```

Listing 1: Κανονικό stratified 75/25 split (encoder/scaler προσαρμοσμένα μόνο στο training partition) και οι κοινές group-fairness μετρικές, που χρησιμοποιούνται από κάθε φάση.

1.2 Tabular VAE (phase3_vae.py)

```

1 class TabVAE(nn.Module):
2     def __init__(self, n_num, cat_card, z_dim=16, hidden=128):
3         super().__init__()
4         self.n_num, self.cat_card, self.z_dim = n_num, cat_card, z_dim
5         d_in = n_num + sum(cat_card)
6         self.enc = nn.Sequential(nn.Linear(d_in, hidden), nn.ReLU(),
7                                   nn.Linear(hidden, hidden), nn.ReLU())
8         self.fc_mu, self.fc_logvar = nn.Linear(hidden, z_dim), nn.Linear(hidden,
9                                   z_dim)
10        self.dec_shared = nn.Sequential(nn.Linear(z_dim, hidden), nn.ReLU(),
11                                         nn.Linear(hidden, hidden), nn.ReLU())
12        self.dec_num = nn.Linear(hidden, n_num) # Gaussian head
13        self.dec_cats = nn.ModuleList([nn.Linear(hidden, k) for k in cat_card]) # softmax heads
14
15    def decode(self, z):
16        h = self.dec_shared(z)
17        return self.dec_num(h), [head(h) for head in self.dec_cats]
18
19    def vae_loss(num_pred, cat_logits, x, n_num, cat_card, mu, logvar, beta=1.0):
20        rec, off = F.mse_loss(num_pred, x[:, :n_num], reduction="sum"), n_num
21        for k, logits in zip(cat_card, cat_logits): # cross-entropy per one-hot block
22            rec = rec + F.cross_entropy(logits, x[:, off:off+k].argmax(1),
23                                       reduction="sum")
24            off += k
25        kl = -0.5 * torch.sum(1 + logvar - mu.pow(2) - logvar.exp())
26        return rec + beta * kl
27
28    @torch.no_grad()
29    def vae_sample(model, n, cat_card, n_num):
30        num, cats = model.decode(torch.randn(n, model.z_dim))
31        parts = [num.numpy()]
32        for logits in cats: # hard Gumbel-Softmax -> valid one-hot
33            parts.append(F.gumbel_softmax(logits, tau=0.5, hard=True).numpy())
34        return np.concatenate(parts, axis=1).astype(np.float32)

```

Listing 2: Hybrid Tabular VAE (Φάση 3): ένα Gaussian head στο numerical block και ένα softmax head ανά one-hot categorical block. Οι synthetic γραμμές υλοποιούν έγκυρα one-hot's μέσω ενός hard Gumbel-Softmax· το β αυξάνεται γραμμικά $0 \rightarrow 1$ στις πρώτες 40 epochs για αποφυγή posterior collapse.

1.3 Πυρήνας TabDDPM (phase4_diffusion.py)

```

1 T = 200
2 betas = torch.linspace(1e-4, 0.02, T)
3 alpha_bar = torch.cumprod(1.0 - betas, dim=0)

```

```

4
5 def sinusoidal_emb(t, dim=64):
6     half = dim // 2
7     freqs = torch.exp(-math.log(1e4) * torch.arange(half) / half)
8     a = t.float().unsqueeze(-1) * freqs.unsqueeze(0)
9     return torch.cat([torch.sin(a), torch.cos(a)], dim=-1)
10
11 class Denoiser(nn.Module):
12     def __init__(self, d_in, t_dim=64, hidden=256):
13         super().__init__()
14         self.t_proj = nn.Sequential(nn.Linear(t_dim, hidden), nn.SiLU())
15         self.in_proj = nn.Linear(d_in, hidden)
16         self.block1 = nn.Sequential(nn.Linear(hidden, hidden), nn.SiLU(),
17                                     nn.Linear(hidden, hidden))
18         self.block2 = nn.Sequential(nn.Linear(hidden, hidden), nn.SiLU(),
19                                     nn.Linear(hidden, hidden))
20         self.out = nn.Linear(hidden, d_in)
21
22     def forward(self, x, t):
23         h = self.in_proj(x) + self.t_proj(sinusoidal_emb(t, 64)) # additive time
24                                     embedding
25         h = h + self.block1(h) # residual block 1
26         h = h + self.block2(h) # residual block 2
27         return self.out(h)
28
29 def q_sample(x0, t, eps): # x_t = sqrt(abar) x0 + sqrt(1-abar) eps
30     a = alpha_bar[t].unsqueeze(1)
31     return a.sqrt() * x0 + (1 - a).sqrt() * eps
32
33 # loss : F.mse_loss(eps_theta(x_t, t), eps) # Ho et al. 2020
34 # sample : ancestral denoise t = T..1, then per one-hot block:
35 # (denoised block ~ one-hot, NOT logits -> argmax, no Gumbel here):
36 # hard[arange(n), block.argmax(1)] = 1.0 # valid one-hot

```

Listing 3: TabDDPM denoiser της Φάσης 4: ένα residual MLP $\varepsilon_{\theta}(x_t, t)$ με ένα *additive* sinusoidal time embedding και δύο residual blocks. Η εκπαίδευση ελαχιστοποιεί το ε -prediction MSE· στο τελικό reverse βήμα κάθε one-hot block γίνεται snap στην επικρατέστερη κατηγορία με argmax.

1.4 DQN-based active learner (phase6_r1_AL.py)

```

1 N_BUCKETS = 20 # 5 candidate features x 4 quantile buckets
2
3 class QNet(nn.Module): # state (20-D) -> Q-values over 20 strata
4     def __init__(self, d_state=20, n_actions=20, hidden=64):
5         super().__init__()
6         self.net = nn.Sequential(
7             nn.Linear(d_state, hidden), nn.ReLU(),
8             nn.Linear(hidden, hidden), nn.ReLU(),
9             nn.Linear(hidden, n_actions))
10    def forward(self, s): return self.net(s)
11
12 def make_state(pool_feats): # per-feature [mean, std, max, q90] ->
13     20-D
14    return np.concatenate([pool_feats.mean(0), pool_feats.std(0),
15                           pool_feats.max(0), np.quantile(pool_feats, 0.9, axis=0)])
16
17 # Reward = improvement in test-set F1 (NOT accuracy -> defuses reward hacking)
18 reward = m_new["f1"] - curve[-1]["f1"]
19
20 # One-step TD update (Huber loss), bootstrapped from the SAME online network:
21 q_now = qnet(S).gather(1, A.unsqueeze(1)).squeeze(1)
22 with torch.no_grad():
23     target = R + gamma * (1 - D) * qnet(Sp).max(dim=1).values

```

```
23 loss = F.smooth_l1_loss(q_now, target)
```

Listing 4: DQN active learner (Φάση 6): ένα 20-D pool-statistics state, 20 stratum actions (5 candidate features $\times$ 4 quantile buckets), reward = ανά-γύρο ΔF_1 (όχι accuracy), και ένα one-step TD update (Huber loss, experience replay, bootstrapped από το online network).

1.5 In-processing fairness MLP (phase8_fairness_inprocess.py)

```
1 def train_fair_mlp(X, y, s, lam, epochs=60, batch=128, lr=1e-3, class_weight=None):
2     model = MLP(X.shape[1]) # same architecture as Phase 2
3     opt = torch.optim.Adam(model.parameters(), lr=lr, weight_decay=1e-5)
4     pos_w = torch.tensor([class_weight]).float() if class_weight else None
5     bce = nn.BCEWithLogitsLoss(pos_weight=pos_w)
6     loader = DataLoader(TensorDataset(X, y, s), batch_size=batch, shuffle=True)
7     for ep in range(epochs):
8         for xb, yb, sb in loader:
9             logits = model(xb); soft = torch.sigmoid(logits)
10            m1, m0 = (sb == 1), (sb == 0)
11            # demographic-parity surrogate, only if BOTH groups present in the batch
12            if m1.any() and m0.any():
13                gap = torch.abs(soft[m1].mean() - soft[m0].mean())
14            else:
15                gap = torch.tensor(0.0)
16            loss = bce(logits, yb) + lam * gap
17            opt.zero_grad(); loss.backward(); opt.step()
18    return model
```

Listing 5: In-processing fairness training loop (Φάση 8). Επαναχρησιμοποιεί το logit MLP της Φάσης-2 με BCEWithLogitsLoss· το διαφορίσιμο demographic-parity surrogate στο $\sigma(z)$ προστίθεται με βάρος λ και εφαρμόζεται μόνο σε mini-batches που περιέχουν και τις δύο προστατευόμενες ομάδες. Σαρώθηκε σε $\lambda \in \{0, 0.1, 0.5, 1, 2, 5, 10\}$.

1.6 Multimodal DistilBERT encoder (phase9_multimodal_bert.py)

```
1 from transformers import AutoTokenizer, AutoModel
2 from sklearn.decomposition import PCA
3 from sklearn.preprocessing import StandardScaler
4
5 tok = AutoTokenizer.from_pretrained('distilbert-base-uncased')
6 mdl = AutoModel.from_pretrained('distilbert-base-uncased').eval() # frozen, no
   fine-tuning
7
8 @torch.no_grad()
9 def encode_comments(comments, batch=32):
10     embs = []
11     for i in range(0, len(comments), batch):
12         enc = tok(comments[i:i+batch], padding=True, truncation=True,
13                   max_length=48, return_tensors='pt')
14         out = mdl(**enc).last_hidden_state # (B, T, 768)
15         mask = enc['attention_mask'].unsqueeze(-1).float()
16         pooled = (out * mask).sum(1) / mask.sum(1).clamp(min=1) # masked mean-pool
17         embs.append(pooled.numpy())
18     return np.concatenate(embs, 0).astype(np.float32)
19
20 # train / test comments follow the SAME 75/25 split as the tabular data
21 emb_tr, emb_te = encode_comments(comments_tr), encode_comments(comments_te)
22 pca = PCA(n_components=32, random_state=42).fit(emb_tr) # train-only fit
23 scaler = StandardScaler().fit(pca.transform(emb_tr)) # train-only fit
24 txt_tr = scaler.transform(pca.transform(emb_tr))
25 txt_te = scaler.transform(pca.transform(emb_te))
```

```

26 X_mm_tr = np.concatenate([X_tab_tr, txt_tr], axis=1) # 247 + 32 = 279
27 X_mm_te = np.concatenate([X_tab_te, txt_te], axis=1)

```

Listing 6: Leakage-safe multimodal κατασκευή χαρακτηριστικών (Φάση 9). Ο DistilBERT encoder είναι frozen· τα σχόλια γίνονται mean-pooled σε 768-D· το PCA (32 PCs) και ένας scaler προσαρμόζονται μόνο στα *training* embeddings και έπειτα επαναχρησιμοποιούνται αμετάβλητα στα test σχόλια, που κωδικοποιούνται με καθαρό inference.

1.7 Σενάριο εκτέλεσης (driver)

```

1 $ cd code
2 $ python phase1_preprocessing.py # EDA, 75/25 split, one-hot + scaling
3 $ python phase2_baselines.py # RF / XGBoost / MLP baselines
4 $ python phase3_vae.py # hybrid Tabular VAE oversampling
5 $ python phase4_diffusion.py # TabDDPM diffusion (Upgrade 1)
6 $ python phase5_uncertainty_AL.py # uncertainty active learning
7 $ python phase6_rl_AL.py # DQN active learning (Upgrade 2)
8 $ python phase7_fairness_posthoc.py # post-hoc fairness audit
9 $ python phase8_fairness_inprocess.py # in-processing fairness (Upgrade 3)
10 $ python phase9_multimodal_bert.py # DistilBERT multimodal (Upgrade 4)
11 $ python phase10_master_comparison.py # master_comparison.csv + summary
12
13 # Each phase writes results/<name>.json and figures/*.png; phases 1/3/4/9
14 # also persist arrays under data/. Paths resolve relative to the repo, and
15 # the raw CSV defaults to ../data.csv (override via the RAW_CSV env var).

```

Listing 7: Αναπαραγωγή: τα δέκα phase scripts τρέχουν με τη σειρά από το code/· καθένα καταναλώνει μόνο τα artefacts που παρήγαγαν προηγούμενες φάσεις. Η raw είσοδος είναι το semicolon-delimited UCI export data.csv.